


一、LLM面临的挑战

1. **制造虚假事实**：LLMs经常制造虚假事实，特别是在处理特定领域或高度专业化的查询时。
2. **知识限制**：当所寻求的信息超出模型训练数据范围或需要最新数据时，LLMs可能无法提供准确答案。
3. **实际应用中的挑战**：在实际生产环境中部署生成型人工智能时，单纯使用“黑盒”LLMs可能不够的。

二、解决方案：RAG（检索增强生成）

RAG提供了一种创新的解决方案，以应对大语言模型（LLM）在处理复杂查询、维持最新的信息以及提高回答的准确性方面遇到的挑战。

RAG通过结合传统的生成式语言模型和动态检索机制，能够实时从广泛的外部知识库中检索信息，以此来增强模型的生成输出。这种方法不仅提高了生成内容的相关性和准确度，还扩展了模型的知识范围，使其能够覆盖训练数据之外的信息。



RAG如何通过外部知识增强来克服这些挑战：

(1) 提升信息的丰富性和准确性

- **动态知识库接入**：RAG通过实时检索最相关的外部文档，引入了最新、最相关的信息作为生成过程的一部分，从而显著提高了回答的准确性和详细程度。
- **上下文感知生成**：结合检索到的文档和原始查询，RAG能够生成更加丰富和具体的内容，尤其是在处理复杂问题或需要详细解释的场景中。

(2) 扩展知识覆盖范围

- **覆盖训练数据之外的信息**：传统LLM可能难以处理未在训练集中直接出现的信息。RAG通过检索来动态地引入外部知识，从而有效地扩展了模型的知识覆盖范围，包括最新的事件、专业知识或者少见的事实。

(3) 增强模型的适应性和灵活性

- **模型更新与维护**：RAG降低了对模型频繁更新的需求，因为它可以通过查询更新的外部知识库来获取新信息。这样不仅减少了持续训练的成本，也使模型能够更快适应新的信息和变化。

- **多领域适用性**：通过访问专业领域的知识库，RAG可以被应用于多个领域，如医疗、法律、科技等，而无需为每个领域单独训练模型。

(4) 解决伦理和偏见问题

- **可追溯的信息源**：RAG的生成内容可以追溯到具体的外部文档，这为验证生成内容的准确性和公正性提供了可能，有助于识别和减少偏见和不准确的信息。

三、RAG 简介

1. RAG的定义

- 检索增强生成 (RAG) 是一种使用来自私有或专有数据源的信息来辅助文本生成的技术，它是一种结合了**检索**和**生成**两个主要组件的语言模型架构，旨在通过检索相关信息来增强模型的生成能力。
- RAG 对于诸如回答问题和内容生成等任务，具有极大价值，因为它能支持生成式 AI 系统使用外部信息源生成更准确且更符合语境的回答。它会实施搜索检索方法（通常是**语义搜索**或**混合搜索**）来回应用户的意图并提供更相关的结果。

2. RAG的原理


2.1 概述

RAG模型的工作可以分为**两个主要步骤**：

- **检索**：
 - 负责从一个大规模的知识库、数据库或外部来源（或者同时从多个来源）中检索出与输入查询最相关的文档或信息片段，检索到的这一信息现在可以作为模型所需要的任何事实或背景信息的参考来源。
 - 检索到的信息会被转化为高维度空间中的向量(embeddings)，这些知识向量会被存储在向量数据库中。
 - 向量模型会基于与输入查询的相关性，对检索到的信息进行排序。分数最高的文档或段落会被选中，以进行进一步的处理。
- **生成**：
 - 接下来，生成模型（例如 LLM）会使用检索到的信息来生成文本回复。
 - 生成的文本可能会经过额外的后处理步骤，以确保其语法正确，语义连贯。
 - 整体而言，这些回复更加准确，也更符合语境，因为这些回复使用的是检索模型所提供的补充信息。

2.2 工作流程

1. **输入查询处理**：接收用户的输入查询。
2. **执行检索**：利用检索器在知识库中找到相关文档。
3. **信息融合**：将检索到的文档与原始查询融合作为生成模型的输入。
4. **内容生成**：生成模型根据融合后的信息产生回答或文本。
5. **输出结果**：向用户展示生成的内容。



3. RAG vs 微调

3.1 关键差异

- **RAG**：依赖外部知识库进行动态检索，以实时更新和扩展模型的知识。
- **微调**：在特定数据集上调整预训练模型的参数，以提高在特定任务上的表现，不涉及实时检索外部信息。

3.2 适用场景

- **RAG**：适用于需要访问和引入大量外部最新信息的场景，如开放域问答、实时内容生成等。
- **微调**：适合于有大量标注数据且领域相对固定的任务，如情感分析、特定领域的文本分类等。

3.3 互补性

RAG和微调不是相互排斥的，而是可以相互补充，从不同层面增强模型的能力。在某些情况下，结合这两种技术可以实现最佳的模型性能。

4. RAG的优势

(1) 准确性提高：

- RAG通过与外部知识相关联的答案来提高准确性，减少语言模型中的幻觉问题，使生成的响应更准确、可靠。

(2) 保持信息的时效性和准确性：

- 与传统只依赖训练数据的语言模型相比，RAG可以识别最新信息，保持响应的时效性和准确性。

(3) 透明度：

- RAG通过引用来源提高答案的透明度，增加用户对模型输出的信任。

(4) 定制化能力：

- RAG可以通过索引相关文本语料库来定制不同领域的模型，为特定领域提供知识支持。

(5) 可扩展性：

- RAG能够处理大规模数据集而无需更新所有参数和创建训练集，使其在经济上更有效率。

(6) 结果的可信度：

- RAG从最新数据中选择确定性结果，而微调模型在处理动态数据时可能出现幻觉和不准确性，缺乏透明度和可信度。

5. RAG的挑战

(1) 准确性依赖：

- RAG在生成响应时依赖于外部知识库的准确性。如果检索到不准确的信息，生成的结果也会出现错误。

(2) 计算成本与速度：

- RAG需要在大型知识库或网络中执行检索，这一过程不仅计算成本高，速度也较慢，虽然与微调模型相比有所提速和成本下降。

(3) 集成设计与优化：

- 要实现检索与生成部分的无缝集成，需要精心设计和优化，这可能在训练和部署过程中带来挑战。

(4) 隐私与合规问题：

- 在处理敏感数据时，从外部来源检索信息可能会涉及隐私问题。需遵守隐私和合规要求，可能限制可访问的信息来源。通过文档级访问权限可以部分解决这一问题。

(5) 创意内容的局限性：

- RAG擅长处理基于事实的内容生成，可能不擅长创作富有想象力或虚构性质的内容，限制了其在创意内容生成领域的应用。

四、RAG 框架




Figure 3: Comparison between the three paradigms of RAG

1. 基础版 - RAG