

- RAG擅长处理基于事实的内容生成，可能不擅长创作富有想象力或虚构性质的内容，限制了其在创意内容生成领域的应用。

四、RAG 框架





Figure 3: Comparison between the three paradigms of RAG

1. 基础版 - RAG



1. 将查询传递给嵌入模型，将其语义表示为嵌入查询向量；
2. 将嵌入查询向量传递给向量数据库或稀疏索引（BM25）；
3. 根据检索器算法获取前k个最相关的块；
4. 将查询文本和检索到的块转发给大型语言模型（LLM）；
5. 使用LLM基于检索到的内容填充提示生成响应。

基础版的RAG过程可以分为三个主要阶段，旨在通过结合检索和生成过程来提高语言模型的输出质量和相关性。

1.1 基本步骤

1.1.1 建立索引

- **数据准备**：在离线状态下对数据进行清理和提取，将多种文件格式转换成统一的纯文本格式，以便于处理和索引。这包括从PDF、HTML、Word、Markdown等文件中提取文本内容。
- **文本处理**：对提取的文本进行分块，以小段落或段落为单位进行处理，以便更精确地检索到与查询最相关的信息。
- **索引创建**：使用向量数据库（如Milvus、FAISS、ElasticSearch）构建文本块的索引。这些索引基于文本内容的向量表示，以支持高效的相似性搜索。

1.1.2 输入增强


- **查询转换**：通过修改输入查询，使用Query2doc和HyDE首先用查询生成一个伪文档，然后使用这个文档作为检索的关键。
- **数据增强**：指在检索前提前改善数据，例如去除无关信息、消除歧义、更新过时的文档，合成新数据等。

1.1.3 检索文档

- **问题向量化**：利用编码模型将用户查询转换为向量表示，与文档块索引中的嵌入进行相似度比较。
- **文档选择**：根据计算得到的相似度，选择最相关的前K个文档块作为问题的上下文增强信息，以供生成阶段使用。

1.1.4 文本生成

- **融合上下文**：将选定的问题和其相关文档块合并成一个新的输入提示，为大型语言模型提供丰富的上下文信息。
- **回答生成**：基于合并后的提示，大型语言模型生成回答。在多轮对话场景中，可以进一步整合历史对话信息，以提升回答的连贯性和相关性。



1.2 挑战

1.2.1 检索质量问题

- **精度和召回率**：挑战包括低精度（不是所有检索到的文档块都与查询严格相关，可能导致信息的断层或误导）和低召回率（未能检索到所有相关文档块，限制了语言模型获取充足上下文的能力）。
- **幻觉与不相关性**：模型可能生成基于错误或不完整上下文的幻觉内容，或生成的回答与查询问题不相关。
- **有害或偏见性内容**：在不适当的上下文引导下，模型可能产生有害或带有偏见的回应。

1.2.2 增强过程的挑战

- **整合检索段落**：有效融合检索到的段落与生成任务当前的上下文，以提高生成内容的相关性和准确性。
- **冗余与重复**：处理多个检索段落中的相似或重复信息，避免在生成的回答中出现重复内容。
- **重要性评估**：评估并确定哪些检索到的文档块对回答生成任务最为关键和相关。
- **风格一致性**：处理不同来源文档的写作风格或语气差异，确保生成的回答在风格和语气上保持一致性。

2. 高级版 - RAG

高级版RAG在基础版的基础上引入了进阶技术和策略，专注于提升检索生成过程的效率和输出质量。它通过细化索引、优化检索过程，并采用高级后处理技术，显著提高了整体性能。

2.1 预检索优化

2.1.1 优化数据索引

- **细粒度索引**：通过更细致地分割文档和使用更丰富的元数据标注，提升了索引的精确度，使得检索过程能够更准确地定位到相关信息。
- **索引结构优化**：改进索引结构，如采用分层或图结构索引，以加速查询响应时间和提高检索效率。
- **元数据添加**：整合额外的文档元数据（如作者、发布日期、文档类型等），支持更复杂的查询需求和改善检索结果的相关性。
- **对齐优化和混合检索**：结合稀疏和密集向量索引，利用不同的检索策略来优化结果，提高检索的灵活性和准确性。

2.1.2 嵌入和索引

- **微调嵌入**：通过在特定领域或数据集上微调语言模型，生成更加精准的文档和查询嵌入，从而提升检索的相关性。
- **动态嵌入**：实现基于上下文的动态词嵌入，允许模型根据查询的具体上下文调整词语的向量表示，增强模型对语义的捕捉能力。

2.2 检索过程优化

2.2.1 重新排序

智能排序：引入基于机器学习的排序模型，如学习排序（Learning to Rank）技术，对初步检索结果进行再排序，确保最相关的信息能够优先呈现给用户。

2.3 生成器增强

2.3.1 提示工程

- 专注于提高语言模型输出质量的技术，如提示压缩、活跃提示、思维链提示等。
- 这些技术适用于RAG系统中的大型语言模型生成器，可以通过压缩查询来加快模型推理速度，减轻不相关信息对模型的负面影响，缓解“中途迷失”现象。

2.3.2 解码调整

- 在生成器处理过程中添加额外控制，如调整超参数以实现更大的多样性，限制输出词汇等。

2.3.3 微调生成器

- 通过微调生成器来增强模型的领域知识或与检索器更好的匹配度。

2.4 高级RAG的特点

- 性能优化：**通过高级的索引方法和精细化的检索策略，高级RAG能够更快速、更准确地定位到查询相关的信息，提高了检索效率和生成内容的质量。
- 适应性强：**结合多种检索技术和策略，高级RAG能够根据不同的查询需求和信息类型，灵活调整检索策略，保证了结果的相关性和丰富性。
- 动态嵌入应用：**通过对嵌入模型的微调和动态调整，高级RAG在处理上下文变化时表现出更高的适应性和准确性，特别是在面对多样化和复杂查询时。
- 高级后处理：**采用先进的后处理技术，如提示压缩和智能重排序，进一步优化生成内容的准确性和一致性，显著提升用户体验。

五、RAG的核心组件

