

BAAI - FlagEmbedding

1. BGE Embedding

BGE Embedding是一个通用向量模型。我们使用[retromae](#)对模型进行预训练，再用对比学习在大规模成对数据上训练模型。

请注意，预训练的目标是重构文本，预训练后的模型无法直接用于相似度计算，需要进行微调之后才可以用于相似度计算。

1.1 案例实战


01_FlagEmbedding_Embedding案例实战.ipynb

2. BGE Reranker


重排器（reranker）使用问题和文档作为输入，直接输出相似度，而不是嵌入向量。通过向重排器输入查询和段落，你可以得到一个相关性得分。重排器基于交叉熵损失（cross-entropy loss）进行优化，因此相关性得分不受限于特定范围。

基于交叉熵损失的优化：重排器的训练通常基于交叉熵损失，这是一种衡量模型预测值与实际值之间差异的方法。通过优化这个损失，重排器学习如何准确地预测查询和文档之间的相关性得分。由于是基于交叉熵损失进行优化，得到的相关性得分没有固定的范围，而是可以根据模型的学习动态调整。

Bi-encoder



Cross Encoder



2.1 案例实战

02_FlagEmbedding_Reranker案例实战.ipynb

3. BGE M3

BGE-M3，一个在多功能性（Multi-Functionality）、多语言性（Multi-Linguality）和多粒度（Multi-Granularity）方面表现出色的模型。

1. 多功能性

- **密集检索（Dense Retrieval）**：BGE-M3能够通过密集向量进行高效的检索。
- **多向量检索（Multi-Vector Retrieval）**：可以处理将文档或查询分解为多个向量的情况，提高检索的准确性和灵活性。
- **稀疏检索（Sparse Retrieval）**：支持传统的基于关键词的稀疏检索方法，增加了模型的适用范围。

2. 多语言性

- **支持语言**：BGE-M3能够支持100多种工作语言，极大地扩展了其应用范围，使其能够适应全球化的需求。

3. 多粒度

- **输入处理**：模型能够处理不同粒度的输入，从短句到长达8192个令牌的长文档，这使得BGE-M3能够适应从简短查询到深入分析长文档的各种场景。

3.1 案例实战

03_FlagEmbedding_BGE-M3案例实战.ipynb

4. C-MTEB

C-MTEB（Chinese Massive Text Embedding Benchmark）：MTEB的中文扩展，收集了35个公开数据集，涵盖6种任务类型，是评估中文文本嵌入通用性的理想基准。

4.1 案例实战

04_FlagEmbedding_C_MTEB案例实战.ipynb

欢迎关注B站/公众号/YouTube：唐国梁Tommy

我的个人网站：TGLTommy.com