

1. 论文名称: C-Pack: Packaged Resources To Advance General Chinese Embedding
2. 团队: BAAI
3. github: <https://github.com/FlagOpen/FlagEmbedding>

Abstract

名称: C-Pack

内容:

- **C-MTEB**: 中文文本嵌入基准测试, 包括6个任务和35个数据集。
- **C-MTP**: 大规模文本嵌入数据集, 基于标注和未标注中文语料, 用于嵌入模型训练。
- **C-TEM**: 多尺寸的嵌入模型系列, 性能超过所有先前模型, 发布时性能提升10%以上。

优化细节:

- 整合并优化了C-TEM的训练方法。

英文资源:

- 发布了英文文本嵌入的数据和模型, 性能达到最先进水平。
- 英文数据集是中文的两倍大。

1 Introduction

1. 重要性

- 应用: 网页搜索、问题回答、检索增强语言模型。
- 连接: 关键在于连接LLMs和外部模块。

2. 挑战

- 统一模型: 处理不同应用的统一嵌入模型的需求。
- 学习难度: 通用文本嵌入比任务特定嵌入更具挑战。

3. 关键因素

- 数据:
 - 规模: 需数亿训练实例。
 - 多样性: 来自广泛来源以提高任务通用性。
 - 质量: 需要适当清洗以减少噪声。
- 训练:
 - 骨干编码器: 需要适合的编码器。
 - 训练配方: 需要复合配方, 不依赖单一算法。

- 预训练: 以嵌入为中心，提升区分能力。
- 微调: 指导为基础，整合不同的表示能力。

4. 基准测试 (Benchmarking)

- **重要性:** 为文本嵌入建立正确的基准测试，以全面评估其性能。
- **BEIR:** 提供了18个评估嵌入通用性能的数据集合，支持不同的检索任务。
- **MTEB:** 提出了更全面的嵌入评估方法，扩展了BEIR，集成了56个数据集，评估文本嵌入的所有重要能力。




Figure 1: The C-Pack resources to support general Chinese embedding.

5. C-Pack资源包

- **C-MTEB (Chinese Massive Text Embedding Benchmark)** : MTEB的中文扩展，收集了35个公开数据集，涵盖6种任务类型，是评估中文文本嵌入通用性的理想基准。
- **C-MTP (Chinese Massive Text Pairs)** : 创建了1亿文本对的大规模训练数据集，整合了标记数据和未标记数据，数据来源于“悟道” (Wudao) 。
- **C-TEM (Chinese Text Embedding Models)** : 提供了小型 (24M)、基础 (102M) 和大型 (326M) 三种模型尺寸的中文通用文本嵌入模型家族，可在效率和效果之间进行权衡。
- **训练配方:** 与资源一起，集成并优化了建立通用文本嵌入的训练方法，包括以嵌入为导向的预训练、通用对比学习和任务特定的微调。

2 C-Pack

在C-Pack部分，首先介绍了C-Pack中的资源，包括基准测试C-MTEB、训练数据C-MTP和模型类别C-TEM。




Figure 2: **Overview of C-Pack**. **C-MTEB** is a benchmark for Chinese text embeddings. **C-MTP** is a large-scale Chinese embedding training dataset. **C-TEM** are state-of-the-art Chinese embedding models. The training recipe is shown at the bottom.

2.1 基准测试：C-MTEB

- C-MTEB为中文嵌入的全面评估建立了基准测试。
- 收集了35个公共数据集，可以用来评估中文文本嵌入。
- 数据集基于嵌入的能力进行分类，涵盖6类评估任务：检索、重排序、语义文本相似性（STS）、分类、对分类、聚类。
- 每个类别都有多个数据集，这些数据集从不同的领域收集，彼此互补。

2.1.1 评估任务和指标

- **检索**：通过NDCG@10作为主要指标来衡量。

指标解释：NDCG@10（Normalized Discounted Cumulative Gain at position 10）是一个衡量排名质量的指标，特别适用于信息检索和推荐系统。NDCG考虑了结果的相关性以及它们在排名中的位置，更重视排名靠前的相关结果。

- **重排序**：使用MAP分数作为主要指标。

指标解释：MAP（Mean Average Precision）是衡量排名效果的指标，特别用于评估重排序任务。MAP考虑了检索出的相关文档在排名中的位置，并计算平均精度（AP）的平均值。

- **STS**：使用Spearman相关性作为主要指标。

指标解释： STS (Semantic Textual Similarity) 任务中使用Spearman相关性来衡量两组数据之间的相关性，特别是文本之间的语义相似度评分。Spearman相关性是一种非参数的秩相关系数，衡量两个变量的秩次之间的相关性。

- **分类：** 使用平均精度作为主要指标。

在分类任务中，平均精度 (Average Precision, AP) 是指对于每个类别，首先计算精度 (预测为该类别的项目中正确预测的比例)，然后计算所有类别的精确度的平均值。

- **聚类：** 使用V-measure分数作为主要指标。

指标解释： V-measure是一个基于熵的聚类评估指标，结合了同质性 (每个聚类只包含单一类的成员) 和完整性 (给定类的所有成员都分配给同一个聚类) 的概念。

2.2 训练数据：C-MTP

C-MTP是为通用中文嵌入训练而创建的最大数据集，由配对文本组成，如问题及其答案、两个意思相近的句子或同一主题的两个文档。C-MTP有两部分组成：C-MTP (未标记) 和C-MTP (标记)。

- **C-MTP (未标记)：** 源自开放网络语料库，如悟道语料库。通过第三方模型Text2Vec-Chinese对关系强度进行评分，筛选出100百万对文本对。
- **C-MTP (标记)：** 涵盖了质量和多样性的数据集，如T²-Ranking、DuReader等，共有838,465对文本。大多数数据是基于人工注释，确保了高相关性。

dataset	C-MTP (unlabeled)	C-MTP (labeled)
source	Wudao, CSL, XLSUM-Zh, Amazon-Review- Zh, CMRC, etc.	T ² -Ranking, mMARCO-Zh, DuReader, NLI-Zh, etc.
size	100M	838K

Table 1: Composition of C-MTP

2.3 模型类别：C-TEM

C-TEM提供了一系列训练良好的嵌入模型。模型采取类似BERT的架构，最后一层的特殊标记 [CLS] 的隐藏状态被训练用作嵌入。提供三种规模的模型：① 大型 (326M参数)、② 基础 (102M参数) 和③ 小型 (24M参数)。大型模型在普遍的表现性能上领先，小型模型在效率和容量上具有竞争力。

C-TEM模型具有很好的通用性，适用于多种任务。它们也可以根据特定场景进行微调，以提高应用性能。C-TEM不仅为人们直接使用嵌入提供了可能，而且还可以作为开发更强大嵌入的基础。

2.4 训练方法




Figure 2: **Overview of C-Pack**. **C-MTEB** is a benchmark for Chinese text embeddings. **C-MTP** is a large-scale Chinese embedding training dataset. **C-TEM** are state-of-the-art Chinese embedding models. The training recipe is shown at the bottom.

训练方法主要包含三个部分：

2.4.1 预训练 (Pre-Training)

- 模型在大规模纯文本上通过定制算法进行预训练，以更好地支持嵌入任务。
- 使用“悟道”语料库进行预训练，该语料库是中文语言模型预训练的大型高质量数据集。
- 采用MAE风格的方法，编码“污染文本”并在轻量级解码器上恢复“清洁文本”。

2.4.2 通用目的微调 (General Purpose Fine-tuning)

- 在C-MTP（未标记）上通过对比学习进行预训练模型的微调，学习区分成对文本与其负样本。
- 对比学习的一个关键因素是负样本。依赖于批内负样本，使用大批量大小以提高嵌入的区分性。

2.4.3 任务特定微调 (Task-specific Fine-tuning)

- 在C-MTP（标记）上进一步微调嵌入模型，标记数据集虽然更小但质量更高。
- 实施了两种策略来缓解不同类型任务可能相互矛盾的影响：
 - 一方面，利用基于指令的微调，为每对文本 (p, q) 附加特定任务指令 I_t 来区分输入。
 - 另一方面，更新负样本采样方法，在批内负样本之外，还为每对文本 (p, q) 挖掘一个硬负样本。

3 Experiments

1. 实验目的：
- 广泛评估中文文本嵌入（C-MTEB）。

◦ 实证验证C-TEM的文本嵌入效果。

◦ 探索C-MTP的实际应用价值。

◦ 分析训练配方的影响。
2. 基线模型：
- 对比包括Text2Vec-Chinese、Luo、M3E、多语言E5和OpenAI文本嵌入ada002等流行模型。

3.1 一般评估结果

- C-TEM在各项任务中表现出色，尤其是在检索、STS、对分类和重排序任务上。

• 虽然分类和聚类任务的优势不太明显，但C-TEM在这些任务上的表现仍然与最具竞争力的模型相当或略好。

• 实验结果证实了C-TEM的强大通用性和适用于不同应用场景的能力。

• 模型规模与性能：

◦ 模型规模扩大带来平均性能提升。

◦ 小型C-TEM模型在性能上甚至超过许多现有的大型模型。

◦ 提供灵活性以根据需要在嵌入质量和运行效率之间进行权衡。

model	Dim	Retrieval	STS	Pair CLF	CLF	Re-rank	Cluster	Average
Text2Vec (base)	768	38.79	43.41	67.41	62.19	49.45	37.66	48.59
Text2Vec (large)	1024	41.94	44.97	70.86	60.66	49.16	30.02	48.56
Luotuo (large)	1024	44.40	42.79	66.62	61.0	49.25	44.39	50.12
M3E (base)	768	56.91	50.47	63.99	67.52	59.34	47.68	57.79
M3E (large)	1024	54.75	50.42	64.30	68.20	59.66	48.88	57.66
Multi. E5 (base)	768	61.63	46.49	67.07	65.35	54.35	40.68	56.21
Multi. E5 (large)	1024	63.66	48.44	69.89	67.34	56.00	48.23	58.84
OpenAI-Ada-002	1536	52.00	43.35	69.56	64.31	54.28	45.68	53.02
BGE (small)	512	63.07	49.45	70.35	63.64	61.48	45.09	58.28
BGE (base)	768	69.53	54.12	77.50	67.07	64.91	47.63	62.80
BGE (large)	1024	71.53	54.98	78.94	68.32	65.11	48.39	63.96

Table 2: Performance of various models on C-MTEB.

3.2 详细分析

对C-MTP和训练配方的详细影响进行了研究，并在表格3和4中呈现了相关的实验结果。

model	Dim	Retrieval	STS	Pair CLF	CLF	Re-rank	Cluster	Average
M3E (large)	1024	54.75	50.42	64.30	68.20	59.66	48.88	57.66
OpenAI-Ada-002	1536	52.00	43.35	69.56	64.31	54.28	45.68	53.02
w.o. Instruct	1024	70.55	53.00	76.77	68.58	64.91	50.01	63.40
BGE- <i>i</i>	1024	63.90	47.71	61.67	68.59	60.12	47.73	59.00
BGE- <i>i</i> w.o. pre-train	1024	62.56	48.06	61.66	67.89	61.25	46.82	58.62
BGE- <i>f</i>	1024	71.53	54.98	78.94	68.32	65.11	48.39	63.96

Table 3: Ablation of the training data, C-MTP, and the training recipe.

Batch Size	256	2,048	19,200
Retrieval	57.25	60.96	63.90
STS	46.16	46.60	47.71
Pair CLF	62.02	61.91	61.67
CLF	65.71	67.42	68.59
Re-rank	58.59	59.98	60.12
Cluster	49.52	49.04	47.73
Average	56.43	57.92	59.00

Table 4: Impact of batch size.

1. C-MTP的影响分析：

- C-MTP（未标记）和C-MTP（标记）对嵌入质量的提升有重大贡献。
- C-MTP（未标记）数据集虽然主要来自未标记语料，但其对模型的训练效果显著。
- 在C-MTP（未标记）上训练后的模型（BGE-中间）已在许多属性上超过基线模型，尤其是在检索任务上。
- C-MTP（标记）虽然数据量较小但质量更高，对最终检查点模型（BGE-终）的微调提供了显著提升。

2. 训练配方的影响：

- 对于对比学习，采用了大批量大小，以便尽可能扩大负样本的数量，提高嵌入的区分性。
- 在任务特定微调中，指令的使用显著促进了针对特定任务的微调效果。
- 采用特定的预训练文本编码器来训练C-TEM，而不是使用像BERT和RoBERTa这样的常见选择。

4. 相关工作

1. 通用文本嵌入的重要性：

- 广泛应用于网络搜索和问题回答，对增强大型语言模型（LLMs）至关重要。
- 与特定任务方法相比，需要适用于更多场景。

2. 最新进展：

- 强调大规模、多样化的训练数据是提升嵌入模型性能的关键。

- 侧重于扩大文本编码器，增强模型的泛化能力。
- 训练配方需要通过预训练、负采样和多任务微调进行优化。
- 突出了改进基准测试的需要，以全面评估文本嵌入性能。

3. 代表性工作：

- BEIR和MTEB等基准测试的开发，以全面评估文本嵌入。

5. 结论

1. C-Pack的介绍：

- 旨在推动通用中文嵌入的进展。

2. C-Pack的核心资源：

- **C-MTEB**：评估中文嵌入通用性的全面基准测试。
- **C-MTP**：由大量未标记和高质量标记数据集策划的训练数据。
- **C-TEM**：不同大小的模型，提供效率和嵌入质量之间的权衡。

3. 公共发布的意义：

- 促进通用中文嵌入的使用和未来的发展。