

文件-1: `embedding_app.py`

将embedding模型基于FastAPI封装为对外提供的API服务

文件-2: `embedding_test.py`

基于requests测试embedding API服务

文件-3: `embedding_concurrent_test.py`

评测API服务的平均响应时间, QPS (每秒查询率), 以下截图是测试结果:

成功请求次数: 1000 / 1000

总测试时间: 44.68秒

平均响应时间: 4.42秒

QPS (每秒查询率): 22.38

2.3 生成式检索 GR, Generative Retriever


生成式检索 (Generative Retrieval, GR) 是一种信息检索技术, 它使用生成式模型来自动构造或生成与给定查询相关的文档标识符或文本响应。

生成式检索(Generative Retrieval) 的核心思想是构建一个 Seq2Seq 生成模型, 输入 query, 直接输出 docID。

在训练阶段, 生成模型将文档内容映射到语义唯一标志符(docID)实现文档的索引;

在推理阶段, 生成模型将查询映射到对应的文档 (docID) 以完成文档检索。

作为对比, 传统的双塔范式是索引+召回&重排。索引, 召回器, 重排器是可以互相独立训练的, 而 GR下面索引+召回&重排的过程直接融合在模型的训练和推理里面。



Memorizing
Generative Retrieval

2.3.1 特点

(1) 优势

1. **深度语义理解**：GR可以理解查询的复杂语义，这使得其能够生成与查询语境相关度更高的结果。
2. **高灵活性**：GR能够生成各种类型的响应，不仅仅限于数据库中预先存在的答案。
3. **可扩展性**：GR通过学习语言模式可以处理各种查询，甚至是模型训练时未见过的查询。
4. **上下文感知**：利用Seq2Seq和变换器架构，GR可以在生成响应时考虑到查询的上下文。
5. **减少手动索引**：GR减少了对人工创建索引的需求，因为它可以直接生成文档标识符。


(2) 劣势

1. **记忆精度**：对细粒度文档特征记忆精度差。
2. **记忆混淆**：语料库规模增加导致记忆混淆，生成不相关或不准确的信息。
3. **更新成本**：新文档带来巨大的记忆更新成本。
4. **资源密集**：GR模型通常需要大量的计算资源来训练和运行。
5. **可解释性差**：与传统方法相比，GR的决策过程可能不透明，缺乏可解释性。

2.4 生成式密集检索 GDR, Generative Dense Retriever

内容来源：北理工 Generative Dense Retrieval: Memory Can Be a Burden

- **应用场景**: 小规模语料库
- **工作机制**: 自回归地编码相关文档标识符以响应查询
- **匹配机制**: 采用粗到细的检索范式，包括群集间匹配和群集内细粒度匹配。使用有限记忆容量实现群集间匹配，再进行群集内细粒度匹配
- **优势**: 结合GR的深度交互优势与DR的可扩展性
- **策略**:
 - 群集识别器构建策略：促进语料库记忆
 - 群集适应性负采样策略：增强群集内映射能力



3. Generator 生成器

在RAG中，生成器是另一个核心组件，负责将检索到的信息转换成自然流畅的文本。与传统的语言模型相比，RAG的生成器通过利用检索到的信息来提高准确性和相关性。在RAG中，生成器的输入不仅包括传统的上下文信息，还包括通过检索器获得的相关文本段落。这使得生成器能够更好地理解问题背后的上下文，并产生更丰富信息的回应。

3.1 后检索处理增强

后检索处理增强涉及到在检索阶段之后，对检索到的信息进行进一步处理和优化，以提升最终结果的质量和相关性。这个过程不仅提高了信息的利用效率，还确保了生成的内容更加符合用户需求。

3.1.1 信息压缩

在大规模信息处理中，即使检索器能够从庞大的数据库中提取相关信息，也存在处理和利用这些信息的挑战。当前的技术发展尽管已经允许了大型语言模型处理更长的上下文，但这些模型的性能仍受到其上下文长度限制的约束。因此，信息压缩成为了一种必要的手段，其目的在于：

- **减少噪声：**通过筛选和压缩信息，去除那些对于回答用户查询不必要的细节，减少干扰信息的影响。
- **应对上下文长度限制：**通过精炼文本，使其精简而不失核心信息，以适应模型的上下文长度限制。
- **增强生成效果：**通过提供更加凝练和高质量的输入信息，帮助生成器产出更加准确和自然的文本。

信息压缩不仅提高了数据处理的效率，还确保了生成内容的质量和相关性。