

1. TEI简介

Text Embeddings Inference (TEI) 是一个用于部署和服务开源文本嵌入和序列分类模型的工具包。TEI 为最受欢迎的模型（包括 FlagEmbedding、Ember、GTE 和 E5）提供高性能提取能力。TEI 实现了许多功能，这些功能包括：

1. **无模型图编译步骤**：这意味着使用 TEI 时，用户不需要进行模型图的编译步骤，可以直接使用模型进行推理，这大大简化了部署流程。
2. **Metal 支持本地执行（适用于 Macs）**：TEI 支持 Metal，这是 Apple 开发的一个图形和计算加速技术，能够在 Mac 设备上本地执行模型，提高执行效率。
3. **小型 Docker 镜像和快速启动时间**：TEI 设计了小型的 Docker 镜像，可以快速启动，适合在无服务器环境下使用，提高了部署效率和响应速度。
4. **基于令牌的动态批处理**：这种方法允许 TEI 根据输入数据的大小和复杂度动态调整批处理大小，从而优化性能。
5. **使用 Flash Attention、Candle 和 cuBLASLt 优化的 Transformer 代码**：这些是用于推理的优化技术，可以提高 Transformer 模型的推理速度和效率。
6. **Safetensors 权重加载**：这是一种安全且高效的方式加载模型权重的方法，有助于提高模型的部署速度和运行时安全性。
7. **生产就绪**：TEI 支持使用 Open Telemetry 进行分布式追踪和 Prometheus 指标，这些特性使得 TEI 适合在生产环境中使用，便于监控和维护。

总的来说，TEI 提供了一个高效且易于部署的解决方案，用于在各种环境中使用文本嵌入和序列分类模型，特别是对于需要快速响应和高性能的应用场景。

2. 环境配置

2.1 创建虚拟环境

```
conda create -n TEI python=3.11
conda init bash && source /root/.bashrc
conda activate TEI
conda install ipykernel
ipython kernel install --user --name=TEI

pip install torch==2.0.1+cu118 torchvision==0.15.2+cu118 --index-url
https://download.pytorch.org/whl/cu118
```

2.2 运行 Text-Embeddings-Inference

2.2.1 下载Embedding模型文件

```
# ① 如果你没有安装 git lfs , 则需要提前安装
# 第一步：下载安装文件
curl -s https://packagecloud.io/install/repositories/github/git-lfs/script.deb.sh |
sudo bash

# 第二步：安装
sudo apt-get install git-lfs

# 第三步：查看是否安装成功
git lfs version

# ② 下载模型文件, bge-large-zh-v1.5
git clone https://huggingface.co/BAAI/bge-large-zh-v1.5
```

2.2.2 安装 Docker

参考链接：[Docker菜鸟教程](#)

如果你已经安装过了，可以跳过这一步骤。

2.2.3 创建shell脚本用于执行Docker命令

① 在本地创建shell脚本：create_docker.sh

```
# --name text_embeddings_container 为容器指定一个名称
# --gpus all 使用本机的所有GPU,也可以指定GPU,例如: --gpus '"device=0"'
# -d 容器运行在后台
# -p 8080:80 主机端口是8080, 容器内端口是80
# -v /root/TEI/models:/data 将主机的/root/TEI/models目录挂载到容器的/data目录
# ghcr.io/huggingface/text-embeddings-inference:turing-1.1 指定使用的Docker镜像以及其版本标签
# --model-id /data/bge-large-zh-v1.5 指定使用的模型ID
docker run -d --name text_embeddings_container --gpus all -p 8080:80 -v
/root/TEI/models:/models ghcr.io/huggingface/text-embeddings-inference:turing-1.1 --
dtype float16 --model-id /models/bge-large-zh-v1.5
```

注意事项：根据你的GPU型号选择对应的镜像文件

Architecture	Image
CPU	ghcr.io/huggingface/text-embeddings-inference:cpu-1.1
Volta	NOT SUPPORTED
Turing (T4, RTX 2000 series, ...)	ghcr.io/huggingface/text-embeddings-inference:turing-1.1 (experimental)
Ampere 80 (A100, A30)	ghcr.io/huggingface/text-embeddings-inference:1.1
Ampere 86 (A10, A40, ...)	ghcr.io/huggingface/text-embeddings-inference:86-1.1
Ada Lovelace (RTX 4000 series, ...)	ghcr.io/huggingface/text-embeddings-inference:89-1.1
Hopper (H100)	ghcr.io/huggingface/text-embeddings-inference:hopper-1.1 (experimental)

② 执行脚本

```
bash create_docker.sh
```

```
(base) root@ubuntu20:~/TEI# bash create_docker.sh
Unable to find image 'ghcr.io/huggingface/text-embeddings-inference:turing-1.1' locally
turing-1.1: Pulling from huggingface/text-embeddings-inference
aece8493d397: Pull complete
9fe5cccca45: Pull complete
8054e9d6e8d6: Pull complete
bddd5cb92f6: Pull complete
5324914b4472: Pull complete
f0b610c7f779: Pull complete
Digest: sha256:6300941bb1e0b89c68487d9476de88d280a231dcc4b16ef4103db1c99fb02204
Status: Downloaded newer image for ghcr.io/huggingface/text-embeddings-inference:turing-1.1
3e21f2d4b0e8fc592ca12ad42a4917503f89fed5094ce014d275a51d7d3e94db
```

③ 查看容器状态

```
docker ps
```

```
(base) root@ubuntu20:~/TEI#
(base) root@ubuntu20:~/TEI# docker ps
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS        PO
RTS           NAMES
3e21f2d4b0e8   ghcr.io/huggingface/text-embeddings-inference:turing-1.1   "text-embeddings-rou..."   11 minutes ago   Up 11 minutes   0.
0.0.0:8080->80/tcp, :::8080->80/tcp   text_embeddings_container
(base) root@ubuntu20:~/TEI#
```

2.2.4 服务测试

```
curl 127.0.0.1:8080/embed \  
-X POST \  
-d '{"inputs": "今天天气很好呀"}' \  
-H 'Content-Type: application/json'
```

```
(base) root@ubuntu20:~/TEI#  
(base) root@ubuntu20:~/TEI# curl 127.0.0.1:8080/embed \  
> -X POST \  
> -d '{"inputs": "今天天气很好呀"}' \  
> -H 'Content-Type: application/json'  
[[-0.0017875314,-0.0011222735,0.03674013,0.022920653,0.044298355,0.015641948,-0.038372528,-0.025000283,-0.011728666,-0.055546246,0.027  
616592,-0.03007637,0.008279388,-0.018627224,0.0013123472,0.0076476717,0.02217154,0.003477231,0.02201501,-0.01871667,0.066369265,-0.036  
85194,-0.052057836,-0.020472057,-0.023658587,-0.030747218,-0.016838295,0.04047452,0.046199095,0.010191306,-0.0598844,-0.024955561,0.02  
5894748,-0.057871856,0.022149177,0.013361064,-0.045125738,0.07433,0.041346624,-0.0050677005,-0.008016638,0.005976141,-0.04320264,-0.01
```

2.2.5 并发测试

运行测试脚本：

```
python embedding_concurrent_test.py
```

```
(base) root@ubuntu20:~/TEI/TEI_project# python embedding_concurrent_test.py  
成功请求次数： 100 / 100  
总测试时间： 0.42秒  
平均响应时间： 0.04秒  
QPS(每秒查询率)： 237.75
```