

BLEU score: 0.046689450558483385

...

(2) ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) 是一种评估自动文摘或机器翻译质量的评价指标，特别是在评估摘要的覆盖度或召回率方面。这里的“召回率”指的是被评估的摘要能在多大程度上覆盖参考摘要中的内容。ROUGE指标与BLEU指标相似，但是**ROUGE更侧重于召回率，而BLEU更侧重于精确度**。

ROUGE的几种变体中，最常见的是ROUGE-N，它计算了参考摘要和生成摘要之间n-gram的重叠情况。计算公式如下：

$$\text{ROUGE-N} = \frac{\sum_{S \in \text{参考摘要}} \sum_{n\text{-gram} \in S} \min(\text{Count}(n\text{-gram}, S), \text{Count}(n\text{-gram}, C))}{\sum_{S \in \text{参考摘要}} \sum_{n\text{-gram} \in S} \text{Count}(n\text{-gram}, S)} \quad (7)$$

其中， C 是机器生成的摘要， S 是参考摘要集合， $\text{Count}(n\text{-gram}, X)$ 是n-gram在文本 X 中的出现次数。

ROUGE-L 是ROUGE的另一个变种，它考虑了最长公共子序列 (LCS)。ROUGE-L的计算不仅仅依赖于n-gram的匹配，而是通过最长公共子序列来衡量整体的序列相似性。其公式如下：

$$R = \frac{\text{LCS}(X, Y)}{|Y|}, \quad P = \frac{\text{LCS}(X, Y)}{|X|} \quad (8)$$

其中， R 是召回率， P 是精确度， $\text{LCS}(X, Y)$ 是参考摘要 Y 和生成摘要 X 的最长公共子序列的长度， $|Y|$ 是参考摘要的长度， $|X|$ 是生成摘要的长度。

>>> 举例讲解

通过一个具体的例子来详细描述ROUGE-N和ROUGE-L的计算过程。

① ROUGE-N 计算过程

假设我们有以下的参考摘要和生成摘要：

- **参考摘要：** The quick brown fox jumps over the lazy dog.
- **生成摘要：** The brown fox jumped over the dog.

为了计算ROUGE-1 (unigram的重叠)，我们首先列出两个摘要中的所有unigrams：

- **参考摘要的Unigrams：** The, quick, brown, fox, jumps, over, the, lazy, dog
- **生成摘要的Unigrams：** The, brown, fox, jumped, over, the, dog

接下来，我们统计生成摘要中每个unigram在参考摘要中出现的次数，并计算总的重叠unigram数：

- The (2次), brown (1次), fox (1次), over (1次), dog (1次) = 6次

然后，我们计算参考摘要中总的unigram数：9个。

ROUGE-1的召回率是生成摘要中重叠unigrams的数量除以参考摘要中unigrams的总数：

$$\text{ROUGE-1 Recall} = \frac{6}{9}$$

如果我们要计算ROUGE-2（bigram的重叠），我们需要列出两个摘要中的所有bigrams：

- **参考摘要的Bigrams**：(The quick), (quick brown), (brown fox), (fox jumps), (jumps over), (over the), (the lazy), (lazy dog)
- **生成摘要的Bigrams**：(The brown), (brown fox), (fox jumped), (jumped over), (over the), (the dog)

重叠的bigrams是：

- (The brown), (brown fox), (over the) = 3次

参考摘要中的bigram总数是8个。

ROUGE-2的召回率是：

$$\text{ROUGE-2 Recall} = \frac{3}{8}$$

② ROUGE-L 计算过程

ROUGE-L是基于最长公共子序列（LCS）。LCS是指不必连续但顺序必须一致的最长子序列。

对于上面的例子，最长公共子序列是：

- **参考摘要和生成摘要的LCS**：The brown fox over the dog

参考摘要的长度是9，生成摘要的长度是7，LCS的长度是6。

ROUGE-L的召回率（R）和精确率（P）分别是：

$$R = \frac{\text{LCS长度}}{\text{参考摘要长度}} = \frac{6}{9}$$

$$P = \frac{\text{LCS长度}}{\text{生成摘要长度}} = \frac{6}{7}$$

(9)

然后，我们可以计算ROUGE-L的F1分数，它是召回率和精确率的调和平均：

$$F1 = \frac{2 \times P \times R}{P + R}$$

将数值代入计算：

$$F1 = \frac{2 \times \frac{6}{7} \times \frac{6}{9}}{\frac{6}{7} + \frac{6}{9}}$$

python 实现

参考摘要和生成摘要

```
reference = "The quick brown fox jumps over the lazy dog"
```

```
generated = "The brown fox jumped over the dog"

# 将摘要分割成单词
reference_tokens = reference.split()
generated_tokens = generated.split()

# 使用集合操作找到最长公共子序列的长度
lcs_set = set(reference_tokens) & set(generated_tokens)
lcs_length = len(lcs_set)

# 计算recall和precision
recall = lcs_length / len(reference_tokens)
precision = lcs_length / len(generated_tokens)

print(recall, precision)

'''输出值

0.6666666666666666 0.8571428571428571
'''
```

>>> ROUGE 计算工具

```
pip install rouge
```

```
from rouge import Rouge

reference = "The quick brown fox jumps over the lazy dog"
generated = "The brown fox jumped over the dog"

rouge = Rouge()
scores = rouge.get_scores(generated, reference)
print(scores)

'''输出值

[{'rouge-1': {'r': 0.6666666666666666, 'p': 0.8571428571428571, 'f': 0.7499999950781251},
  'rouge-2': {'r': 0.25, 'p': 0.3333333333333333, 'f': 0.2857142808163266},
  'rouge-l': {'r': 0.6666666666666666, 'p': 0.8571428571428571, 'f': 0.7499999950781251}}]
'''
```