

1. 论文名称: Bridging the Preference Gap between Retrievers and LLMs

Abstract

- **研究主题：**大型语言模型（LLMs）与信息检索（Retrieval）的关系
- **背景：**
 - **LLMs的表现：**在广泛的任务上展示出优越性能
 - **信息检索：**作为获取任务相关信息的有效方式
- **存在问题：**
 - **RAG的有效性：**在知识密集型任务中通过定位和放置相关信息在LLM上下文中
 - **研究空白：**检索器与LLMs之间的关系未被充分探索
 - **现有研究局限：**将检索器和LLM看作独立组件，未能桥接人类友好信息与LLM友好上下文
- **研究内容：**
 - **桥接模型：**提出并检验一个新的模型
 - **排名和选择假设的验证：**在RAG上下文中
 - **训练框架的提出：**结合监督学习和强化学习的训练框架
- **研究成果：**
 - **实验结果：**证明了桥接模型在问答和个性化生成任务上的有效性

1 Introduction

- **大型语言模型（LLMs）：**介绍了GPT-3和PaLM2等LLMs在多种语言任务中的出色表现。
- **信息检索增强生成（RAG）：**提到RAG能从外部数据集中检索知识，这在许多知识密集型任务中也取得了强大的结果。
- **研究空白：**尽管有广泛的RAG研究，大部分研究仍然将检索器和LLMs分开研究。
- **人类与LLMs的差异：**在设计用户友好的检索器时，一般认为排名非常重要，因为人类通常从上到下阅读。然而，LLMs展示出与人类不同的偏好，并且只有在提示符与这些偏好一致时才能做出准确的预测。
- **偏好差异（preference gap）：**由于上述差异，当前的RAG系统设计可能不够理想，称这种现象为“偏好差异”。
- **关键洞见：**对排名和选择的经验研究表明，LLMs对检索结果的排名不那么敏感，而选择可能更为关键。这证实了检索器和LLMs之间的偏好差异，并强调了桥接这一差异的重要性。
- **桥接模型（BGM）：**为了更好地桥接检索器和LLMs之间的差异，提出了一个名为BGM的新模型，该模型在检索器和LLM之间起到桥梁的作用，将检索信息转换成LLMs可以有效工作的格式。
- **序列到序列（seq2seq）模型：**与传统的打分模式相反，该桥接模型采用了seq2seq模型，不仅可以重新排名，还可以为每个查询动态选择段落，并有潜力采用更高级的策略，如重复使用。




图1：我们观察到在LLM的输入上下文中改变排名和选择时存在偏好差距。实验中我们使用GTR (Ni等人, 2021) 作为检索器，并使用固定的Palm2-S作为LLM。“Top-K”意味着我们选择Top-K GTR检索的段落。不同颜色表示不同的数据集。选定的段落用作附加上下文。我们看到选择 (Top-1) 对模型性能有显著影响 (正面或负面)，而排名 (随机Top-5) 则影响不大 (指标详见第5.2节)。

2 Related work

- **信息检索增强生成 (RAG)**：通过从各种知识来源检索相关信息来增强LLMs，已经在多个NLP任务中显示出有效性，包括语言建模、问答、事实核验和文本生成。
- **RAG的组成**：RAG具有两个主要组件：
 1. **检索器 (retriever)**：从大型语料库中检索一组项目。
 2. **LLM**：将检索到的段落作为额外信息整合到输入上下文中，用于做出最终预测。
- **关键问题**：LLMs和现有检索器之间的不同偏好，只有当它们的偏好得到满足时，LLMs才能表现最佳。桥接这种偏好差异至关重要。
- **挑战分类**：根据需要更新的组件，挑战可以分为三类：
 1. **联合微调检索器和LLMs**：最常用的方法，但大多数LLMs由于商业考虑不是开源的，仅通过APIs以黑箱形式提供。
 2. **仅微调LLMs**：更新LLMs不总是可行的，因为它成本高并且需要定期更新文档索引。
 3. **仅微调检索器**：仅更新检索器以确保它们可以检索与LLMs兼容的段落。
- **RAG中的强化学习 (RL)**：在LLM时代之前，RL已用于信息检索，将IR问题构架为一个马尔可夫决策过程，并使用RL算法解决。但没有工作探讨RL在RAG背景下的应用。
- **BGM与现有方法的区别**：BGM专注于LLMs和检索器之间的偏好差异，不微调LLMs或检索器，而是在它们之间训练一个桥接模型。




图2：与以前将LLM、检索器或两者之一进行更新的RAG不同，BGM不仅将LLM视为黑箱，还冻结了检索。为了使检索到的信息适应LLM的偏好，只有轻量级的桥接模型（Seq2seq LMs）是可调的。这使得BGM适用于大型LLMs，这些LLMs通常通过API提供服务，也避免了检索器的昂贵更新。

3 问题定义

- **检索器**：给定输入 x ，检索器旨在从语料库 $D = \{d_i\}_{i=1}^m$ 中检索与 x 相关的排序段落列表。这里使用了一个固定的密集检索器，采用双编码器结构，编码器将输入上下文 x 和段落 d 编码成嵌入 $E(d)$ 。输入和段落嵌入之间的相似性通过它们的余弦相似度计算：

$$s(d, x) = \cos(E(d), E(x))$$

然后选择与输入 x 相似度得分最高的前 k 个段落。

- **RAG的桥接模型**：为了适应检索到的顶部 k 段落以帮助LLM在下游任务中做出更好的预测，提出了一种桥接模型 B 来调整检索段落，使之成为LLM友好的段落。桥接模型是一个seq2seq模型，它将所有检索到的段落作为输入，输出一组适应的段落。这种格式的优势在于seq2seq模型自动通过生成下一个基于前一个的标记来考虑排名，并通过将句子结束标记放在适当位置来进行选择。注意 n 可能不等于 k 因为进行了选择。
- **RAG与桥接模型**：给定从桥接模型中获得的适应段落作为上下文，将它们与输入 x 连接，并将得到的长序列送入LLM，以获得下游任务的输出。

4 桥接模型的训练方法

由于没有可检索段落真实标签，且LLM被假设为没有梯度的API，因此训练桥接模型具有挑战性。为了解决这个问题，提出了一个结合监督学习（SL）和强化学习（RL）的方法。其中，SL用于减少搜索空间并提供一个初始模型，该模型进行排名和选择。同时，RL用于优化策略模型，即桥接模型，以获得奖励。




图3：展示BGM的训练过程：步骤1：首先，我们通过检索到的序列的贪婪搜索为监督学习（SL）准备银通道序列。步骤2：这个银通道序列用于桥梁模型的监督训练。桥梁模型是一个seq2seq模型，它以查询、通道ID和通道内容作为输入，并输出通道ID。步骤3：最后，训练好的桥梁模型被视为策略模型，并使用强化学习进一步训练。

4.1 监督学习

在进行SL时，需要为每个查询生成真实的序列。在典型的RAG中，查询的真实相关段落通常不提供，更不用说真实序列了。为了解决这个问题，提出了使用贪婪搜索来合成有用段落的“银色序列”。贪婪搜索是一种逐步选择可以最大化下游任务性能的下一个段落的方法。合成银色段落序列使用的是贪婪搜索，假设给定任意长度的段落序列作为上下文的下游任务性能表示为 $R(\cdot)$ 。没有检索到的段落序列，即空的段落序列 $d_0^{\text{retr.}}$ ，有其下游任务性能 $R(d_0^{\text{retr.}})$ 。从 $d_0^{\text{retr.}}$ 和空的银色段落序列 $d_0^{\text{silv.}}$ 开始，尝试添加（即连接）可以最大化银色段落序列性能的候选段落，直到不再有改进为止。训练使用银色段落序列是直接的，通过应用交叉熵损失来实现。

4.2 强化学习（RL）

- 问题：**尽管监督学习（SL）有助于训练桥接模型，但仍然存在性能不稳定的问题，因为仅使用SL会导致性能不稳定。这主要是由于监督信息稀疏和缺乏下游结果的端到端训练。
- 强化学习的应用：**为了解决这些问题，作者提出使用RL来进一步训练桥接模型。RL不限制可能的段落序列，可以容纳更复杂的操作，如重复，并提供更多的监督来找到最佳的段落序列。RL使用下游任务的性能作为奖励，以端到端的方式训练桥接模型。
- RL问题的构建：**
 - 奖励：**任务对其真实标签的性能，因为我们关注的是带标签的下游任务。
 - 策略模型：**需要训练的桥接模型。

- **动作空间**：限制为段落ID，因为我们感兴趣的是调整检索到的段落。
- **训练**：奖励目标可以通过任何现成的RL算法优化，例如近端策略优化（Proximal Policy Optimization, PPO）。

5 实验

5.1 数据集和基线

- **数据集**：
 - **开放域问答（Open-domain QA）**：使用了两个开放域问答数据集进行评估——自然问题（Natural Questions, NQ）和HotpotQA。这两个数据集都包含了问题、答案以及从维基百科和网络中收集的解释。
 - **个性化生成**：遵循Li等人（2023）构建个性化生成数据集。该任务基于用户当前正在编写的文档，以及用户以前撰写的文档作为个人上下文，目的是完成文档仿佛是由用户自己完成的。数据集包括Avocado Email（邮件）和Amazon Book（书籍）。
- **基线方法**：
 - **GTR**：一个广泛认可的独立于LLMs操作的检索器。
 - **Random**：GTR的变种，随机化检索到的段落排名。
 - **PSR**：是Izacard等人（2022）的变种，使用LLM替换编码器并应用逐点评分重新排名。这种方法可以被视为使用重排序器作为桥接模型，但缺乏动态选择的能力。
 - **Naive**：一个非检索基线，生成过程中不进行检索辅助。

	#Training	#Val.	#Test	Avg. # words
NQ	79,168	8,757	3,610	517.82
HotpotQA	68,659	5,600	5,600	564.83
Email	13,305	764	1,227	173.85
Book	20,789	41,331	41,331	124.52

Table 1: Statistic of the 4 datasets.

5.2 LLM 和超参数

- 选择了T5-XXL（11B）模型作为大多数实验的桥接模型。
- 在监督学习阶段，对T5-11B模型进行了微调，基础学习率设置为0.001。
- 使用了1000步的线性预热调度器，并应用了学习率的平方根归一化衰减。
- 模型训练直至在验证集上性能收敛。
- 解码时使用了大小为4的beam search。

作为LLM，使用了新的顶尖模型PaLM2，并采用温度采样作为解码策略。PaLM2的参数被冻结，温度设置为0以使输出确定性。使用精确匹配（EM）和BLEU作为指标来选择最佳提示（prompt）变体，这也用于RL阶段训练桥接模型时的奖励。在公式2中提到的“Top-K”设置为5。

5.3 评估结果和分析

1. BGM在所有四个数据集中的所有基线上表现更优。
2. 与Naive方法相比，BGM显示出显著的整体改进，但在Book数据集上改进较小，可能是因为LLM已经具有大量相关知识。
3. 与GTR方法相比，BGM显示出最显著的改进，特别是在HotpotQA数据集上，表明HotpotQA可能对不相关段落更敏感。
4. 与PSR方法相比，BGM再次显示出显著改进，表明仅重新排名是不够的，还必须考虑选择。

Model Metric	NQ EM	HotpotQA EM	Email BLEU	Book BLEU
Naïve	33.07	28.01	5.57	11.5
Random	43.71	26.10	8.55	8.61
GTR	43.79	25.80	9.76	8.75
PSR	43.60	25.51	9.08	9.14
BGM	45.37	35.64	10.42	12.07

Table 2: Performance of all 4 datasets

Model Metric	NQ EM	HotpotQA EM	Email BLEU	Book BLEU
Naive	33.07	28.01	5.57	11.5
PSR	43.6	25.51	9.08	9.14
PSR (Top1)	42.02	32.69	7.28	11.53
PSR (Top2)	42.54	31.05	7.77	10.11
PSR (Top3)	42.85	32.71	8.21	9.70
PSR (Top4)	43.71	32.37	8.26	9.11
BGM	45.37	35.64	10.42	12.07

Table 3: Ablation results - threshold the PSR

6 结论

- 文章强调了桥接检索器和大型语言模型（LLMs）之间偏好差异的重要性，并展示了这一差异的存在，特别是在排名和选择方面。
- 提供了一个重要的指导，即在检索增强生成（RAG）系统中应该实现什么。

- 提出了一个轻量级的桥接模型的开发，该模型旨在将检索器检索到的段落转换为更适合LLMs的格式。
- 为了实现这些目标，引入了一个名为BGM的新系统。BGM将桥接任务视为一个序列到序列（seq2seq）问题，允许同时考虑排名和选择。
- BGM的训练结合了监督学习和强化学习，便于基于下游任务性能的桥接模型的端到端训练，即使LLM是黑盒（例如，通过API）也能够实现。
- 通过大量的实验验证了BGM的有效性。