

1. 论文名称: ACTIVERAG: Revealing the Treasures of Knowledge via Active Learning
2. 团队: 东北大学 (中国)
3. github: <https://github.com/OpenMatch/ActiveRAG>

Abstract

1. 研究主题:
 - 新型检索增强生成(RAG)框架: ACTIVE RAG
2. 研究背景:
 - 传统RAG模型将大型语言模型(LLMs)作为被动的知识接收器, 限制了学习和理解外部知识的能力。
3. 研究创新:
 - ACTIVE RAG引入了积极学习机制, 改变了LLMs的知识获取方式。
 - 采用了知识构建机制, 通过将外部知识与先前获得或记忆的知识相关联, 促进深入理解。
 - 设计了认知连接机制, 将思维和知识构建的成果融合, 校准LLMs的内在认知。
4. 研究成果:
 - 实验结果表明, ACTIVE RAG在问答数据集上相较于之前的RAG模型有5%的性能提升。

1 Introduction

1. 学习观点:
 - 引言以建构主义的观点开始, 强调学习者不是通过被动感知获取知识和理解, 而是通过经验和社会交往来构建新的理解和知识。
2. 大型语言模型 (LLMs) :
 - 提及了GPT-4和LLaMA等大型语言模型, 这些模型在多种自然语言处理 (NLP) 任务中展现出强大的能力。
3. 现有问题:
 - 指出LLMs常常受到幻觉问题和过时参数记忆的影响, 导致输出不可靠。
 - 引入了检索增强生成 (RAG) 模型, 用于帮助LLMs更新学到的知识, 尤其是在知识密集型任务中。
 - RAG模型通过检索外部语料库, 建立了基于暴力检索的RAG体系结构, 但这种方法的有效性受到检索知识噪音的影响。
4. 知识学习过程:
 - 近期研究集中在通过自我反思和自我完善减少检索文章噪音的影响。
 - 尝试过滤掉无关文章或进行总结性记述, 以提取关键知识点, 这在帮助LLMs生成更准确的答案方面显示了有效性。
5. ACTIVE RAG的提出:

- 强调了尽管RAG模型的自我完善取得了成功，但它们仍将LLM作为外部信息的被动接收者。
- 提出ACTIVE RAG模型，它利用积极学习来增强知识理解，通过桥接先前知识和检索信息的差距，使LLM能够产生准确的答案。
- ACTIVE RAG增强了LLMs的积极学习能力，并采用检索、知识构建和认知连接三个阶段的流水线来构建RAG模型。
- 最后，利用认知连接机制将外部知识与LLMs的内在认知相连接。

6. 实验结果：

- 使用ChatGPT-3.5开发ACTIVE RAG模型，并通过各种问答数据集验证了其有效性，比基线模型有超过5%的改进。
- ACTIVE RAG表现出鲁棒性，能够在不同的数据集和不同数量的检索文章中保持稳定性能。
- 进一步分析显示，知识构建的结果可以推广到不同的LLM架构，如LLaMA2-7B/13B，在利用外部知识方面实现了超过20%的改进。

2 Related Work

1. RAG模型的目标与效果：

- 目的：检索外部知识来增强语言模型，克服纯参数模型的限制。
- 效果：在多种NLP任务中表现出效力，例如问答、对话理解、代码生成等。

2. RAG模型的工作机制：

- 使用密集检索器作为寻找知识的模块。
- 语言模型根据检索到的知识生成结果。

3. 早期RAG模型的发展方向：

- 优化模型以更好地利用外部知识。
- 目标包括发展生成器架构、训练更准确的检索器、联合训练检索器和生成器。

4. RAG模型在LLMs中的应用：

- 降低LLMs的生成困惑度。
- 减轻LLMs的幻觉问题，更新过时和长尾知识。

5. RAG模型面临的挑战：

- 检索内容的噪音对RAG模型的有效性构成挑战。

6. 改进RAG模型的措施：

- 从检索的内容中排除不相关的上下文。
- 增强RAG模型的鲁棒性。
- 使用自然语言推理模型选取相关句子、汇总模型提取必要语义。

7. RAG模型的最新进展：

- 适应性检索文章。
- 构建知识点汇总机制以提高生成准确性。

8. RAG模型与建构主义理论：

- 尽管取得了进展，但LLMs在获取额外知识时仍过于被动，忽视了建构主义理论，即将外部知识与先前知识关联起来的理论。

3 方法论

- 目标：引导大型语言模型（LLMs）主动阅读、理解并利用外部知识进行生成。
- 结构：首先介绍RAG模型基础（3.1节），然后描述ACTIVE RAG方法如何激发LLMs主动学习（3.2节）。

3.1 RAG模型基础

- 定义：利用检索模型搜索文章，提升语言模型的生成能力。
- 典型实践：Vanilla RAG，将检索到的文章直接喂给语言模型以回答问题。
- 挑战：检索文章含噪声，可能限制RAG建模的效益。

3.1.1 RAG模型的发展

- 自我完善RAG：采用检索-完善-生成架构，增强RAG的能力。
- 代表方法：
 - Self-RAG：侧重于微调LLMs，实现适应性检索和信息流控制。
 - Chain-of-Note：通过自我完善检索文章，进行以查询为中心的总结。

Query: Who was the **producer** of **The Woods**?

Retrieved Passages:

Robert Woods is a classical music **producer**. Woods is a founder and former president ...



...

The Woods is a 2011 film written and directed by **Matthew Lessner** and starring Toby David and Justin Phillips.

Vanilla RAG



Answer: The **producer** of The Woods was **Robert Woods**. ❌

Chain of Note



Reading Notes: **The Woods** is a 2011 film written and directed by **Matthew Lessner** ...

Relevance: The passages are **not directly relevant** to answering the question about the **producer** of the film.

Answer: Therefore, based on the given information, the specific producer of the film **remains unknown**. ❌

ActiveRAG



Active Learning: The **contradictory** information in the passages is the mention of **Robert Woods** as a classical music **producer** and founder of Telarc International Corporation, which does **not align with the** question about the producer of the film **The Woods**. ✓

Answer: The **producer** of The Woods was **Matthew Lessner**.

Figure 1: Illustrations of Different RAG Models. Vanilla RAG and Chain-of-Note (Yu et al., 2023b) employ passive learning processes, whereas ACTIVERAG involves active knowledge acquisition.

3.1.2 积极学习与ACTIVE RAG

- 现有方法忽略了积极学习的本质，即学习者通过结合新旧信息主动构建理解和知识。

3.2 ACTIVE RAG：搭配主动知识学习的RAG

1. ACTIVE RAG概念：

- 灵感来源于建构主义学习理论，旨在构建一种新的RAG架构，教会LLMs自己主动获取知识。

2. ACTIVE RAG方法：

- 设计了三步流水线，包括检索、知识构建和认知连接。

- 与自我完善的RAG模型不同，ACTIVE RAG着重于通过桥接检索到的文章和LLMs先前学到的知识之间的差距来进行主动知识学习，无需微调。

3. 知识构建：

- ACTIVE RAG将LLM视为一个认知结构，负责接收、理解和转换文章中的外部知识。

4. 认知连接：

- 使用认知连接机制帮助LLMs利用外部知识进行增强，促进构建的知识理解与LLMs的内在认知过程融合。




Figure 2: The Overview of Our ACTIVERAG Model.

A. 检索的文章（Retrieved Passages） 图片的左上角部分展示了一个查询：“The Woods”的制作人是谁。为回答这个问题，列出了几个检索到的相关文章。这些文章包含有关Robert Woods的信息，他是一位古典音乐制作人，也是Telarc Corporation的创始人和前总裁。还有关于2011年由Matthew Lessner编写并导演的电影“The Woods”的信息，以及1999年由Rick Famuyiwa导演，Omar Epps主演的电影“The Wood”的信息。

B. 知识构建（Knowledge Construction） 在检索的文章下方，介绍了四种知识构建方法：

- Associate：帮助LLM更全面地理解问题，扩展知识边界。
- Anchoring：为LLM提供未知知识，帮助其更好地理解问题。
- Logician：为LLM提供可以增强模型逻辑推理能力的知识。
- Cognition：更新LLM的知识，防止事实错误，减轻模型的错觉问题。

C. 认知连接 (Cognitive Nexus) 图片中心下方展示了认知连接部分，这是ACTIVE RAG模型的一个关键环节，它通过“思维链” (chain of thought) 的方式，指导解决问题的过程。指示LLM进行逐步思考和推理，然后给出答案。认知连接旨在验证上述推理过程中的错误，然后利用检索到的知识加深对问题的理解。

D. 答案 (Answer) 最终，在认知连接的辅助下，得出了答案。文章中的矛盾信息是提到Robert Woods作为一位古典音乐制作人，这与问题不符。正确的答案是Matthew Lessner，这一答案经过可靠来源验证。

整个图示是ACTIVE RAG模型的流程图，描绘了从检索到的文章中抽取信息，通过不同的知识构建策略，最终形成认知连接并生成答案的过程。这个模型的目标是提高LLMs在开放领域问答任务中的性能，特别是在理解和处理复杂、有歧义的信息时。

3.3 不同学习视角下的知识构建

建构主义理论认为学习是一个涉及构建内部心理表征的主动过程，这些心理表征包括丰富的结构化经验背景。

ACTIVE RAG通过提示LLMs作为四种代理来从检索的文章中获取知识，以促进使用记忆中的知识的主动学习。

3.3.1 知识构建的四个角度

- 语义关联 (Associate)：鼓励模型整合熟悉的信息，通过合并基础和高级信息片段来加深理解。
- 认知锚定 (Anchoring)：专注于对模型来说未知的信息，帮助LLMs主动分析和构建对未知内容的知识。
- 逻辑推理 (Logician)：利用结构化信息进行逻辑推导，提炼模型的问题解决能力。
- 认知对齐 (Cognition)：调整现有的心理结构以融入新知识，防止事实错误并减轻LLMs的幻觉问题。

4 实验方法

1. 实验数据集：

- 使用四个公开领域问答数据集评估ACTIVE RAG的性能，包括Natural Questions、PopQA、TriviaQA和WebQ。
- 随机抽取每个数据集500个问题样本，以适应ChatGPT的推理成本。

Dataset	#Query	Sampling Rate
PopQA	14,267	3.5%
TriviaQA	8,837	5.7%
NQ	8,757	5.7%
WebQ	2,032	24.6%

Table 1: Data Statistics. Each dataset consists of randomly sampled 500 questions from the raw dataset.

2. 评估指标：

- 使用准确率 (Accuracy, Acc) 作为评估指标。
- 首先将LLM的输出和标准答案转换为小写，然后进行字符串匹配 (StringEM)。

3. 基准模型：

- 将ACTIVE RAG与包括提示学习和RAG模型在内的几个基准模型进行比较。
- 所有基准模型使用的提示模板在附录A.3中展示。

4. 提示学习：

- 首先用ChatGPT处理QA指令进行标准答案生成，然后实现思维链模式。

5. RAG建模：

- 实现包括vanilla RAG、Chain-of-Note、Self-Rerank和Self-Refine在内的四个基准RAG模型。
- vanilla RAG模型直接将排名最高的文章提供给LLM。
- Chain-of-Note模型总结检索到的文章以辅助生成答案，而Self-Rerank和Self-Refine模型在不微调LLM的情况下过滤掉不相关内容。

6. 实验细节：

- 使用GPT模型的OpenAI API来评估ACTIVE RAG的性能。
- 在生成过程中，以0.2的温度设置运行基于gpt-3.5-turbo-1106的基础模型。
- 使用T5-ANCE从KILT-Wikipedia检索每个问题的top-k相关文档。
- 检索模型通过OpenMatch工具包实现。

5 评估结果

展示了ACTIVE RAG的整体性能，分析了不同知识构建机制的特点和知识构建结果的泛化能力，并展示了案例研究。

5.1 总体表现

Method	Model	Top-5				Top-10			
		NQ	TriviaQA	PopQA	WebQ	NQ	TriviaQA	PopQA	WebQ
w/o RAG	ChatGPT-3.5	51.6	88.8	46.6	52.2	51.6	88.8	46.6	52.2
	CoT	53.6	89.4	45.0	56.6	53.6	89.4	45.0	56.6
	Guideline	54.4	88.2	45.0	46.2	54.4	88.2	45.0	46.2
Vanilla RAG	ChatGPT-3.5	48.6	82.8	54.4	36.4	53.2	86.6	57.6	42.4
Self-Refined RAG	Self-Rerank	47.6	83.6	53.6	35.6	48.6	83.0	56.2	37.6
	Self-Refine	46.6	80.6	53.2	34.8	48.6	79.6	56.4	36.0
	Chain-of-Note	56.4	86.2	64.6	51.4	61.8	88.0	69.0	54.0
ACTIVERAG	w. Associate	62.2	93.0	68.4	62.4	63.8	93.0	70.8	61.4

Table 2: Overall Performance. In our experiments, we utilize the top 5 and top 10 ranked passages to evaluate the model's performance. All models are implemented using ChatGPT-3.5. We present the performance results of ACTIVERAG, which is implemented using the Associate-based knowledge construction method.

- ACTIVE RAG在不同的开放领域QA数据集上的表现在表2中显示。
- 与多个基线模型比较，包括没有RAG的LLMs、vanilla RAG模型和自我完善的RAG模型。

1. 性能比较：

- vanilla RAG模型在不同QA数据集上表现出差异。

- 将文章输入到ChatGPT-3.5后，在WebQ数据集上表现下降，而在TrivialQA和NQ数据集上的表现与之前的工作相似。

2. ACTIVE RAG的优势：

- 与所有基线模型相比，ACTIVE RAG在所有数据集上都有超过5%的改善，特别是在WebQ数据集上表现出色。
- ACTIVE RAG一致地在所有数据集上显著优于ChatGPT-3.5模型，显示出该方法指导LLMs从检索的文章中通过主动学习发掘有价值知识的能力。

3. 进一步的实验：

- 展示了使用5个和10个排名最高的文章进行RAG结果的实验。
- 所有基线RAG模型在提供了更多检索文章用于生成时都表现出一致的改善。
- ACTIVE RAG在提供前5个或前10个文章时表现出几乎相同的性能，表明从前5个文章中提取的信息足以提示LLMs生成正确的答案。
- ACTIVE RAG在利用知识构建帮助下从检索的文章中发掘必要知识方面证明是有效的。

5.2 消融研究 (Ablation Study)

- 进行消融研究以展示认知连接方法的有效性，通过将不同的知识构建方法与思维链结合。
- 使用不同方法处理检索到的文章，并构建认知连接以辅助LLMs。
- 实验结果表明，与使用原始检索文章的RAG模型相比，结合认知连接方法的CoT w. Passage在性能上有所提升。

Method	Setting	Top-5				Top-10			
		NQ	TrivialQA	PopQA	WebQ	NQ	TrivialQA	PopQA	WebQ
RAG	Vanilla	48.6	82.8	54.4	36.4	53.2	86.6	57.6	42.4
CoT	Vanilla	53.6	89.4	45.0	56.6	53.6	89.4	45.0	56.6
	w. Passage	61.2	91.0	61.0	59.4	60.4	91.2	62.2	59.4
	w. Note	61.2	91.8	56.2	60.2	61.8	91.0	58.0	61.0
ACTIVERAG	w. Anchoring	60.2	92.4	63.6	59.8	61.6	92.2	64.4	59.0
	w. Logician	60.0	91.0	67.0	56.0	63.0	91.2	68.6	58.2
	w. Cognition	60.6	91.8	67.2	59.2	60.6	92.2	68.4	59.6
	w. Associate	62.2	93.0	68.4	62.4	63.8	93.0	70.8	61.4
	Oracle Rerank	69.4	95.2	75.0	66.6	70.0	95.2	79.0	67.6

Table 3: Ablation Studies. ACTIVERAG designs different knowledge construction methods and we present the oracle reranking results of these knowledge construction methods to demonstrate the upper bound performance by integrating all these approaches. The **best** and second-best evaluation results are highlighted.

5.3 知识构建机制的特点

- 揭示Associate基于知识构建方法的特性，该方法与简单总结的思维链方法不同。
- Associate方法产生的结果更接近于Anchoring，表明这两种机制主要关注从检索文章中提取知识。




Figure 3: The Text Similarity between Associate and Other Knowledge Construction Method. In our experiments, we use the BLEU-2 score for evaluation.

5.4 知识构建成果的泛化能力

- 展示了使用不同LLMs的知识构建结果的质量。
- 使用ACTIVE RAG的成果来引导性能较弱的LLMs，如LLaMA2-7B/13B，生成答案。
- 与没有RAG的LLMs相比，即使是使用细化过的笔记，检索到的文章也经常成为影响模型性能的噪声。
- 知识构建的成果使LLaMA2-7B/13B在所有QA数据集上的性能提高了超过20%。

Methods	NQ	TriviaQA	PopQA	WebQ
<i>LLaMA2-7B</i>				
Vanilla RAG	26.4	41.8	30.8	24.8
Chain-of-Note	22.0	45.2	38.1	21.0
CoT	32.2	66.0	25.2	41.8
LLM w/o RAG	26.8	53.2	21.6	40.2
w. Associate	50.6	87.4	55.8	49.6
w. Anchoring	52.4	88.6	51.6	54.0
w. Logician	51.2	87.6	59.6	50.2
w. Cognition	54.4	87.2	58.4	50.6
PPL-Rerank	53.4	87.6	56.2	50.8
<i>LLaMA2-13B</i>				
Vanilla RAG	29.0	39.0	22.8	25.2
Chain-of-Note	22.0	46.0	30.6	22.8
CoT	34.0	73.2	31.6	48.8
LLM w/o RAG	30.6	57.2	32.2	44.6
w. Associate	53.2	89.6	57.4	52.6
w. Anchoring	51.6	88.2	50.6	53.8
w. Logician	57.8	90.3	65.4	53.0
w. Cognition	51.2	88.6	52.4	51.6
PPL-Rerank	55.2	89.4	61.8	53.2

Table 4: Generalization Effectiveness of the Outcomes of Chain-of-Note and ACTIVERAG. The 5 top-ranked passages are used for augmentation. The **best** and second-best evaluation results are highlighted.

5.5 案例研究 (Case Studies)

- 随机选择一个案例在表5中展示ACTIVE RAG的有效性。
- 知识构建机制在形成知识理解方面表现出其有效性，提供了回答问题的关键线索。
- ACTIVE RAG支持LLMs结合外部知识和内在认知来生成答案。

Question: Which sports event was first held at Worcester, Massachusetts in 1927? **Answer:** The first Ryder Cup

Chain-of-Thought:

1. Think about sports events that could have been held in Worcester, Massachusetts in 1927.
2. Consider the popularity of different sports at that time.
3. Try to recall any historical events or records related to sports in Worcester in 1927.

Answer: The first American Motorcycle Association (AMA) dirt track race.

Step 1: Passage Retrieval

Passage 1: Worcester now hosts the Massachusetts Pirates, an indoor football team in the National Arena League ... The city previously was home to the New England Surge of the defunct Continental Indoor Football League.

Passage 2: Worcester Country Club is a private country club. The course hosted the first Ryder Cup in 1927. One of three golf courses in the United States to host the men's and women's U.S. Hazeltine made it an elite group of three upon its host of the 2016 Ryder Cup. Worcester also hosted the first-ever U.S. Open qualifying round in 1924.

Passage 3: Worcester, Massachusetts is home to minor league sports teams ... Many historic and local sporting events have occurred in Worcester such as the first official Ryder Cup golf tournament at Worcester Country Club in 1927.

Passage 4: The first public basketball game was played in Springfield, Massachusetts, on March 11, 1892.

Step 2: Knowledge Construction using Associate Agent

Foundational Knowledge: Worcester, Massachusetts has a history of hosting various sports events, including golf tournaments, basketball games, and minor league sports teams. The Worcester Country Club hosted the first Ryder Cup in 1927, making it a significant location for the event ...

Advanced Information: Details about specific sports events and teams that have been hosted or based in Worcester, such as the Worcester Busters, Worcester Boosters, and Worcester Panthers baseball teams ...

Analyzing the Role of Information: Worcester, Massachusetts has a rich sports history and has been a significant location for various sports events and teams. The hosting of the first Ryder Cup in 1927 at the Worcester Country Club highlights the city's importance in the world of golf. Additionally, the presence of minor league sports teams and professional franchises demonstrates the city's active participation in a wide range of sports. This information deepens the model's understanding of the question by providing context about the sports culture in Worcester and expanding its knowledge boundaries about the specific events and teams associated with the city.

Step 3: Cognitive Nexus

1. Identify popular sports events in 1927, considering Worcester, Massachusetts as the location.
2. Worcester, Massachusetts has a rich history in sports, particularly in baseball and golf. The Worcester Country Club hosted significant events such as the first Ryder Cup in 1927 and the 1925 U.S. Open.
3. The Worcester Country Club also hosted the 1960 U.S. Women's Open and was the site of the first-ever U.S. Open qualifying round in 1924, further solidifying its importance in the sports world.
4. Considering the historical significance of the Worcester Country Club in hosting major golf events, it is likely that the sports event first held at Worcester, Massachusetts in 1927 was the first Ryder Cup.

Table 5: Case Study. We present one case to show the pipeline of ACTIVERAG, which includes passage retrieval, knowledge construction and cognitive nexus steps. The answers and relevant contents are highlighted.

6 结论

- 本文提出的ACTIVE RAG框架整合了主动知识学习，这一点受到了建构主义理论的启发。
- ACTIVE RAG通过知识构建和认知连接机制来促进检索知识与LLMs内在认知的整合。

局限性

- ACTIVE RAG在帮助LLMs利用外部知识进行生成任务中证明是有效的，且无需微调模型。
- 但这需要多次调用ChatGPT API：一次用于构建初始思维链，一次用于处理知识构建结果，最后一次用于执行认知连接以生成最终答案。
- 这可能会带来额外的时间延迟和API调用成本，并且由于包含了大量检索的文章和知识构建结果，输入到LLMs的内容往往较长。

问答

(1) Active RAG 的策略与普通的RAG策略有什么区别？

ACTIVE RAG模型与传统的RAG模型的主要区别在于它采取了一种主动学习的方法来处理和利用检索到的信息，而不是简单地将检索到的文本作为生成答案的直接输入。下面是两种策略的主要区别：

1. 知识构建策略：

- **传统RAG**：一般将检索到的通道直接输入到语言模型中，依赖于模型本身的能力来理解和使用这些通道中的信息。
- **ACTIVE RAG**：采用建构主义学习理论，通过知识构建（Knowledge Construction）和认知连接（Cognitive Nexus）来整合检索到的信息，并与模型的先前知识相结合。它促使模型通过主动学习来加深对问题的理解，而不是仅仅作为信息的被动接收者。

2. 认知连接（Cognitive Nexus）：

- **传统RAG**：可能没有专门的机制来整合检索到的信息与模型的内在认知过程。
- **ACTIVE RAG**：通过认知连接机制，将检索到的知识与模型的内在认知过程相结合，形成了一个思维的链条，引导模型从检索的信息中构建答案。

3. 对抗噪声和误导信息：

- **传统RAG**：可能会受到检索结果中的噪声和不准确信息的影响，导致生成的答案出现偏差。
- **ACTIVE RAG**：通过知识构建过程识别并修正可能的错误信息，减少了由于误解检索通道而产生的幻觉问题。

4. 模型微调（Fine-tuning）：

- **传统RAG**：可能需要对特定的任务或数据集进行微调。
- **ACTIVE RAG**：主张无需微调模型，而是通过ACTIVE RAG框架的内置机制来提升LLM的性能。

总的来说，ACTIVE RAG模型的目标是实现一种更动态和交互式的信息处理方法，使LLMs能够更有效地利用外部知识源，从而提高问题解答的准确性和深度。

举例说明

我们可以通过一个模拟的问答任务来具体说明ACTIVE RAG是如何工作的。假设我们的问题是：“牛顿的三大运动定律是什么？”

这里是ACTIVE RAG处理这个问题的步骤：

步骤1：问题理解

- 首先，ACTIVE RAG模型需要理解问题的含义。模型会分析问题中的关键词“牛顿”和“三大运动定律”。

步骤2：信息检索

- 接下来，模型会在一个大型的知识库中搜索与“牛顿”和“三大运动定律”相关的信息。
- 假设检索结果返回了多个相关的段落，包括牛顿生平的描述、经典力学的介绍以及三大定律的具体内容。

步骤3：知识构建

- ACTIVE RAG现在会采取知识构建策略，使用以下方法：
 - **Associate**（关联）：模型会筛选与问题直接相关的信息，并将它与已有的科学知识关联起来，例如，识别出三大定律的科学术语和它们的物理意义。
 - **Anchoring**（锚定）：模型将特别关注以前可能不太熟悉的信息，例如牛顿定律的具体应用实例。
 - **Logician**（逻辑）：在此阶段，模型运用逻辑推理来整合定律的描述，以确保对问题的回答逻辑上是准确的。
 - **Cognition**（认知）：最后，模型会更新其对物理运动定律的整体理解，确保新信息没有与已知事实相冲突。

步骤4：认知连接

- 通过认知连接阶段，ACTIVE RAG模型将上述知识构建的结果与问题的上下文结合起来，形成一个完整的思维链条。
- 比如，模型可能会形成这样的链条：“牛顿的第一运动定律（惯性定律）说明.....；第二定律（ $F=ma$ ）定义了力和加速度的关系；第三定律（作用与反作用）则表述了.....”

步骤5：生成答案

- 综合考虑所有这些信息，ACTIVE RAG模型现在准备好生成答案。
- 最终的答案可能是：“牛顿的三大运动定律包括：1) 惯性定律，物体会保持静止状态或匀速直线运动，除非受到外力作用；2) 力和加速度定律，即 $F=ma$ ；3) 作用与反作用定律，即每个作用力都有一个等大反方向的反作用力。”

步骤6：验证和修正

- 在生成答案之后，ACTIVE RAG模型还会检查答案的准确性，如果有需要，会进行修正，以确保提供的信息是准确无误的。

通过这个过程，ACTIVE RAG不仅仅是检索然后重复信息，而是通过主动的学习和理解过程，将检索到的知识转化为对问题的深刻理解和精确答案。