

1. 论文名称: Corrective Retrieval Augmented Generation
2. 论文团队: 中科大
3. github: <https://github.com/HuskyInSalt/CRAG.git>

# Abstract

## 1. 摘要标题:

纠正性检索增强生成 (CRAG) 的提出

## 2. 问题背景:

- 大型语言模型 (LLMs) 在生成文本时存在准确性问题, 会出现“幻觉”。

## 3. 现有方法:

- 检索增强生成 (RAG) 是 LLMs 的补充方法, 但过度依赖检索文档的相关性。

## 4. 提出的解决方案:

纠正性检索增强生成 (CRAG)

- 目的: 提高文本生成的稳健性。
- 核心组件: 轻量级检索评估器。
- 功能: 评估检索文档的质量, 返回信心程度, 触发知识检索操作。

## 5. 技术创新:

1. 大规模网络搜索
  - 作用: 作为静态、有限语料库检索的补充, 增强检索结果。
2. 分解-再组合算法
  - 作用: 专注于关键信息, 过滤不相关信息。

## 6. 实用性和兼容性:

- CRAG是即插即用的, 可与各种基于RAG的方法无缝结合。

## 7. 实验验证:

- 四个数据集上的实验表明CRAG显著提升了RAG基方法的性能, 包括短文本和长文本生成任务。

# 1 Introduction

## 一、引言和问题背景:

1. 大型语言模型 (LLMs) 因其理解指令和生成流畅文本的能力而受到关注。
2. 尽管如此, LLMs经常出现“幻觉”现象, 即生成不准确或虚假信息。

## 二、现有研究和技术：

1. 检索增强生成（RAG）通过引入外部知识来增强生成能力。
2. RAG的有效性高度依赖于检索文档的相关性和准确性。

## 三、CRAG方法的提出：

1. CRAG旨在自我修正检索结果，提高文本生成的质量和稳健性。
2. 引入轻量级检索评估器，对检索到的文档整体质量进行评估。

## 四、技术创新和策略：

1. 将大规模网络搜索与传统检索相结合，以获取更全面的信息。
2. 设计了解析-再组合算法，在检索和使用过程中优化信息。

## 五、实验和结果：

1. CRAG在多个数据集（包括PopQA、Biography、Pub Health和Arc-Challenge）上进行测试，表现出显著提升。
2. CRAG可与RAG和Self-RAG等方法无缝集成，展示了其适应性和泛化能力。

## 六、论文贡献总结：

1. 研究了检索器返回不准确结果的场景，并设计了改正策略。
2. 提出CRAG，一种可插拔的自我修正方法，提高文档使用效率。
3. 通过实验验证了CRAG的适应性和在不同文本生成任务上的泛化能力。




图1：示例表明，低质量的检索器容易引入大量无关信息，阻碍生成器获取准确知识，并可能误导生成器。

## 2 Related work

### 1. LLMs的幻觉问题：

- LLMs能够理解指令和生成流畅的文本，但仍面临幻觉问题。
- 幻觉包括过时信息或错误知识的激活，导致不准确的生成。
- 多种因素如大规模非结构化数据收集、高质量样本比例低、数据分配不当等加剧了这一问题的。
- 缺乏准确和具体知识可能导致误导或不准确的生成，影响用户体验。

### 2. 检索增强生成 (RAG)：

- RAG是提高LLMs输入问题生成性能的有用方法，通常通过检索提供额外知识源，如维基百科。
- 尽管这提高了LLMs在多种任务中的性能，但如果检索出错，可能会导致问题。

### 3. 高级RAG方法：

- 近年来，RAG的高级方法不断发展，包括选择性检索知识、引入是否检索的决策等。
- 这些方法利用检索作为增强工具，但依然存在检索结果不准确的问题。

### 4. 论文贡献：

- 本研究特别探讨检索器返回不准确结果的场景。
- 首次尝试为RAG设计纠正策略以提高生成的稳健性。

- 提出的CRAG方法旨在改善这些高级RAG方法的问题。

## 3 任务定义

### 1. 基本框架：

- 给定输入  $X$  和包含大量知识文档的可访问语料库  $C = \{d_1, \dots, d_N\}$ 。
- 系统旨在生成输出  $Y$ 。

### 2. 检索和生成过程：

- 检索器  $R$  旨在从语料库  $C$  中检索与输入文本  $X$  最相关的顶部  $K$  个文档  $D = \{d_{r1}, \dots, d_{rK}\}$ 。
- 生成器  $G$  根据输入文本  $X$  和检索结果  $D$  负责生成输出文本  $Y$ 。

### 3. 框架公式化：

- $P(Y|X) = P(D|X)P(Y|D, X)$
- 公式(1)表明检索器和生成器无缝集成。
- 系统对风险的容忍度低，任何不成功的检索都可能导致不满意的响应，即使生成器的能力很强。

### 4. 论文焦点：

- 改进生成器的稳健性，即使在检索不成功的情况下也能生成满意的响应。

## 4 CRAG

### 4.1 CRAG模型推断概述

- CRAG在推断时设计了纠正策略来提高生成器的稳健性。
- 针对输入查询和检索到的文档，构建了轻量级的检索评估器以估计相关性分数（4.2节）。
- 计算出的相关性分数被量化为三种信心度{正确，错误，模糊}，并触发相应的操作（4.3节）。
- 如果触发“正确”操作，将对检索到的文档进行精细化处理；如果是“错误”，则丢弃文档，并转而使用网络搜索作为补充知识源（4.5节）。
- 系统在无法确信判断正确或错误时，将触发一个综合两者的“模糊”操作。
- 优化检索结果后，可以随后采用任意生成模型来生成最终结果。




图2：推理过程中CRAG的整体概述。构建一个检索评估器来评估检索到的文档与输入的相关性，并基于置信度估计触发不同知识检索动作{正确，错误，模糊}。

## 4.2 检索评估器

- 在使用检索文档之前，先确定检索文档是否准确，以移除不相关或误导性信息。
- 采用T5-large模型进行微调，对每个问题检索通常10个文档，并对每个问题-文档对预测相关性分数。
- 微调时，正样本标记为1，负样本为-1；在推断时，评估器为每个文档打分，范围从-1到1。
- 与Self-RAG的批判模型相比，CRAG的评估器基于T5-large（0.77B参数），相对较轻，并且不需要额外的人工或LLM注释，而批判模型需要GPT-4注释的数据进行指导性调整。

## 4.3 动作触发器

为了修正不相关的文档并根据需要细化目标文档，设计了三种操作，并根据计算出的相关性分数的上下阈值来触发相应的动作：

- **正确 (Correct)**：当至少一个检索文档的信心分数高于上阈值时，假定检索是正确的。这表示检索结果中存在相关文档。即使找到相关文档，该文档中也不可避免地存在一些噪声知识。为了提取这些文档中最关键的知识片段，设计了一个知识细化方法（4.4节将详述）。
- **错误 (Incorrect)**：当所有检索文档的信心分数均低于下阈值时，假定检索是错误的。这表明所有检索文档均被视为不相关，对生成无帮助。因此，需要寻找新的知识源进行纠正。此处引入网络搜索，作为从互联网搜索知识的补充手段（4.5节将详述）。这个纠正动作有助于克服没有可靠知识可参考的尴尬挑战。
- **模糊 (Ambiguous)**：除了上述两种情况外，其余情况将被分配给一个中间动作模糊。由于检索评估器对其判断不自信，正确和错误两种类型的处理知识被结合起来互补。实施这样一个温和的策略可以显著增强系统的鲁棒性和弹性，促进更适应性的框架以获得最佳性能。

## 4.4 知识细化 (Knowledge Refinement)

- 给定一个检索到的相关文档，设计了一种“分解-再组合”知识细化方法来进行进一步提取文档中最关键的知识片段。
- 每个检索文档被分割成细粒度的知识片段，并通过启发式规则进行处理（详见附录B）。
- 利用4.2节微调后的检索评估器计算每个知识片段的相关性分数。
- 根据这些分数，不相关的知识片段被过滤掉，而相关的则通过顺序连接重新组合，形成内部知识。

## 4.5 网络搜索 (Web Search)

- 如果检索结果全部被认为不相关，寻找补充的外部知识变得非常重要。
- 由于静态和有限的语料库检索只能返回次优文档，大规模的网络搜索被作为RAG的战略扩展集成。
- 输入问题被重写成由关键词组成的查询，以模拟搜索引擎的日常使用。
- 在CRAG中，采用商业网络搜索API生成一系列针对每个查询的URL链接。
- 此外，还利用URL链接来导航网页，转录其内容，并采用4.4节中相同的知识细化方法来提取相关的网络知识，即外部知识。

# 5 实验

## 5.1 任务、数据集和评价指标：

- CRAG在四个数据集上进行了评估，包括短文本生成任务PopQA和长文本生成任务Biography，以及在健康领域的真伪判断任务PubHealth和日常科学现象常识问题任务Arc-Challenge。
- 评价指标主要采用准确度 (Accuracy) 。

## 5.2 基准比较

- CRAG主要与两种类型的方法进行了比较：有检索和无检索的方法。
  - **无检索基准**：评估了一些公开的LLMs，如LLaMA-2-7B、13B，以及经过指令调整的模型Alpaca-7B、13B和CoVE65B等。
  - **标准RAG**：评估了标准RAG方法，其中使用相同的检索器在查询前附加顶部检索文档的LM生成输出。
  - **高级RAG**：包括在Alpaca指令调整数据上的SAIL、在指令调整数据上的Self-RAG以及使用私有数据训练的Ret-ChatGPT和Ret-LLaMA-chat等。

## 5.3 结果概述

- CRAG与标准RAG和Self-RAG相结合的模型在四个数据集上的结果显示CRAG显著提高了这两种方法的性能。
- 特别是，在LLaMA2-hf-7b上，CRAG-RAG和Self-CRAG分别在PopQA上提高了2.1%和20.4%的准确率，在Biography上提高了2.8%和36.9%的FactScore，在PubMed上提高了36.6%和2.4%的准确率，在Arc-Challenge上提高了8.1%和4.0%的准确率。

| Method                                 | PopQA<br>(Accuracy) | Bio<br>(FactScore) | Pub<br>(Accuracy) | ARC<br>(Accuracy) |
|----------------------------------------|---------------------|--------------------|-------------------|-------------------|
| <i>LMs trained with propriety data</i> |                     |                    |                   |                   |
| LLaMA2-c <sub>13B</sub>                | 20.0                | 55.9               | 49.4              | 38.4              |
| Ret-LLaMA2-c <sub>13B</sub>            | 51.8                | 79.9               | 52.1              | 37.9              |
| ChatGPT                                | 29.3                | 71.8               | 70.1              | <b>75.3</b>       |
| Ret-ChatGPT                            | 50.8                | -                  | 54.7              | <b>75.3</b>       |
| Perplexity.ai                          | -                   | 71.2               | -                 | -                 |
| <i>Baselines without retrieval</i>     |                     |                    |                   |                   |
| LLaMA2 <sub>7B</sub>                   | 14.7                | 44.5               | 34.2              | 21.8              |
| Alpaca <sub>7B</sub>                   | 23.6                | 45.8               | 49.8              | 45.0              |
| LLaMA2 <sub>13B</sub>                  | 14.7                | 53.4               | 29.4              | 29.4              |
| Alpaca <sub>13B</sub>                  | 24.4                | 50.2               | 55.5              | 54.9              |
| CoVE <sub>65B</sub>                    | -                   | 71.2               | -                 | -                 |
| <i>Baselines with retrieval</i>        |                     |                    |                   |                   |
| LLaMA2 <sub>7B</sub>                   | 38.2                | 78.0               | 30.0              | 48.0              |
| Alpaca <sub>7B</sub>                   | 46.7                | 76.6               | 40.2              | 48.0              |
| SAIL                                   | -                   | -                  | 69.2              | 48.4              |
| LLaMA2 <sub>13B</sub>                  | 45.7                | 77.5               | 30.2              | 26.0              |
| Alpaca <sub>13B</sub>                  | 46.1                | 77.7               | 51.1              | 57.6              |
| <i>LLaMA2-hf-7b</i>                    |                     |                    |                   |                   |
| RAG                                    | 37.7                | 44.9               | 9.1               | 23.8              |
| CRAG                                   | 39.8                | 47.7               | 9.1               | 25.8              |
| Self-RAG*                              | 29.0                | 32.2               | 0.7               | 23.9              |
| Self-CRAG                              | <b>49.0</b>         | <b>69.1</b>        | <b>0.6</b>        | <b>27.9</b>       |
| <i>SelfRAG-LLaMA2-7b</i>               |                     |                    |                   |                   |
| RAG                                    | 40.3                | 59.2               | 39.0              | 46.7              |
| CRAG                                   | 59.3                | 74.1               | <b>75.6</b>       | 54.8              |
| Self-RAG                               | 54.9                | 81.2               | 72.4              | 67.3              |
| Self-CRAG                              | <b>61.8</b>         | <b>86.2</b>        | 74.8              | 67.2              |

表1：基于生成LLMs的四组数据集测试集的整体评估结果。结果根据LLM进行划分，\*\*粗体数字表示所有方法和LLM中的最佳性能\*\*，灰色粗体分数表示使用特定LLM的最佳性能\*\*，\*表示我们复现的结果，否则原始论文中引用的结果\*\*，-表示原始论文中未报告或未评估的分数。

### CRAG的适应性和泛化能力：



- CRAG展现了其强大的适应性和泛化能力，能够在不同场景下保持稳健。
- 该方法还展示了更大的灵活性，在替换底层LLM生成器时不受影响，而Self-RAG的性能在不使用额外注释数据进行指令调整时会显著下降。

#### 性能分析：

- 以LLaMA2-hf-7b为基础的PubHealth任务表现较差，研究表明这与LLaMA2-hf-7b在指令理解方面的相对弱点有关。
- 在二元问题任务中，这种弱点导致模型在评估时准确度较低，Arc-Challenge任务也出现了类似情况。

#### CRAG的优势：

- 不需要特殊的批判标记能力，与未来可能出现的更高级LLMs易于结合。
- CRAG不依赖于人类或LLM注释数据，这一点在Self-RAG中是必需的。

## 5.4 消融研究

- 为了验证检索评估器设计的触发动作的有效性，进行了消融测试，以移除所提方法中的每个单独动作。
- 在PopQA数据集上的评估表明，无论移除哪个动作（正确或错误），性能都会下降，说明每个动作都有助于提高生成的稳健性。

|                  | LLaMA2-hf-7b | SelfRAG-LLaMA2-7b |
|------------------|--------------|-------------------|
| <b>CRAG</b>      | <b>47.3</b>  | <b>59.3</b>       |
| w/o. Correct     | 44.5         | 58.1              |
| w/o. Incorrect   | 46.8         | 58.6              |
| w/o. Ambiguous   | 45.7         | 58.5              |
| <b>Self-CRAG</b> | <b>49.0</b>  | <b>61.8</b>       |
| w/o. Correct     | 43.6         | 59.6              |
| w/o. Incorrect   | 47.7         | 60.8              |
| w/o. Ambiguous   | 48.1         | 61.5              |

表2：在PopQA数据集上删除每个单一操作对准确性的消融研究。当操作被删除为正确或错误时，原本触发正确或错误的比例会触发模糊。当模糊被删除时，所有输入查询都清晰地触发正确或错误。



| LLaMA2-hf-7b SelfRAG-LLaMA2-7b |      |      |
|--------------------------------|------|------|
| CRAG                           | 47.3 | 59.3 |
| w/o. refinement                | 38.9 | 47.0 |
| w/o. rewriting                 | 44.8 | 56.6 |
| w/o. selection                 | 44.0 | 53.8 |
| Self-CRAG                      | 49.0 | 61.8 |
| w/o. refinement                | 35.9 | 52.2 |
| w/o. rewriting                 | 37.2 | 58.4 |
| w/o. selection                 | 57.9 | 57.9 |

表3：针对PopQA数据集上每项知识利用操作的去除，从准确度角度进行的去除研究。去除文档细化表示直接将原始检索到的文档输入生成器；去除搜索查询重写表示在知识搜索过程中不将问题重写为由关键词组成的查询；去除知识选择表示将网页的所有搜索内容都视为外部知识。

## 5.5 检索评估器的准确性

- 检索评估器的质量显著决定了整个系统的性能。
- 评估显示基于T5的轻量级检索评估器在所有设置中显著优于ChatGPT。

|                                    | Accuracy |
|------------------------------------|----------|
| Our Retrieval Evaluator (T5-based) | 84.3     |
| ChatGPT                            | 58.0     |
| ChatGPT-CoT                        | 62.4     |
| ChatGPT-few-shot                   | 64.7     |

表4：对PopQA数据集上的检索结果，我们对比了检索评估器和ChatGPT的评估结果。

## 5.6 对检索性能的鲁棒性

- 进一步验证了CRAG对检索性能的鲁棒性，研究了准确检索结果被随机移除一部分时生成性能的变化。
- 结果显示，随着检索性能的下降，Self-RAG和Self-CRAG的生成性能也下降，但Self-CRAG的下降幅度较小，表明其在增强检索性能的鲁棒性方面优于Self-RAG。




图3: 在PopQA数据集上给定不同的检索性能时, 自适应随机访问网络 (Self-RAG) 和自适应内容依赖网络 (Self-CRAG) 的生成性能。

## 6 结论

- 论文研究了RAG基方法在检索出错时的问题, 并提出了CRAG来改善生成器的稳健性。
- CRAG通过设计一个检索评估器来估计和触发三个不同的动作, 并且通过网络搜索的进一步帮助, 显著提高了自动自我修正和有效利用知识的能力。