

1. 论文名称: RAPTOR: RECURSIVE ABSTRACTIVE PROCESSING FOR TREE-ORGANIZED RETRIEVAL
2. 论文团队: 斯坦福
3. github: <https://github.com/parthsarathi03/raptor>

Abstract

- **模型名称:** RAPTOR
- **模型类型:** 检索增强型语言模型
- **改进点:**
 - 适应世界状态变化
 - 融入长尾知识
- **现有方法的局限:** 仅检索短连续文本块, 限制了对整体文档环境的全面理解
- **RAPTOR的创新方法:**
 - **递归嵌入:** 对文本块进行嵌入
 - **聚类:** 对嵌入的文本块进行聚类
 - **总结:** 对聚类后的文本块进行总结
 - **树状结构构建:** 从下至上构建具有不同总结级别的树状结构
- **推断时的操作:** 从树状结构中检索信息, 整合跨不同抽象级别的文档信息
- **实验结果:** 控制实验显示RAPTOR在多个任务上比传统检索增强型语言模型有显著提升
- **特别性能提升:**
 - 在需要复杂多步推理的问答任务中展现最先进的结果
 - 结合GPT-4使用时, 在QUALITY基准测试中准确率提高20%的绝对值

1 Introduction

- **大型语言模型(LLMs)的作用:**
 - 展现出出色的性能
 - 作为独立的高效知识存储库
- **LLMs的局限性:**
 - 缺乏足够的领域特定知识
 - 难以适应世界的快速变化
- **现有检索增强方法的缺点:**
 - 仅检索短小的连续文本块
 - 限制了大规模话语结构的表示和利用

- **RAPTOR系统的创新点:**

- 利用树状结构捕获文本的高级和低级索引和检索
- 通过聚类和总结文本块构建树状结构
- 能够在不同级别上回答问题

- **研究贡献:**

- 提出文本总结用于不同规模的上下文检索增强
- 展示了在长文档集合上的实验有效性

- **实验结果:**

- RAPTOR超越了现有检索增强
- 与UnifiedQA、GPT-3和GPT-4结合使用，在三种QA任务上取得最新进展
 - 自由文本响应问题
 - 全文NLP论文
 - 基于中等长度段落的多项选择问题




图1：树构建过程：RAPTOR根据文本块的向量嵌入进行递归聚类，并从底部生成这些聚类的文本摘要，从底部构建树。聚在一起的节点是兄弟节点；父节点包含该簇的文本摘要。

2 Related work

- **为什么使用检索:**

- 模型处理长文本能力受限
- 长上下文使用成本高且效率低
- 选择最相关信息对知识密集型任务至关重要

- **检索方法:**

- **检索增强型语言模型 (RALLMs):** 改进包括检索器、阅读器、端到端系统训练
- **传统技术:** TF-IDF
- **深度学习策略:** BM25
- **大型语言模型作为检索器:** 利用其存储大量知识的能力

- **集成不同检索方法的模型:**
 - Fusion-in-Decoder (FiD)
 - Dense Hierarchical Retrieval (DHR)
 - 其他集成DPR和BM25的模型
- **检索组件的方法多样性:**
 - 标准方法通常基于BERT的检索器
 - 连续性可能无法捕捉文本的全部语义深度
 - 提取的片段可能忽略重要上下文
- **递归总结作为上下文:**
 - **总结技术:** 提供文档的浓缩视图
 - **递归抽象总结模型:** 通过任务分解总结小块文本
 - **LlamaIndex方法:** 总结相邻文本块并保留中间节点的细节
 - **RAPTOR:** 发现并整合文本内部的远距离相互依赖

3 Method

- **RAPTOR模型构建概览:**
 - 通过递归树结构平衡主题广度和细节深度
 - 初始构建: 将检索语料库分割成每个100词的短块，并使用SBERT进行嵌入
- **聚类算法:**
 - 采用聚类算法将相似的文本块分组
 - 使用语言模型对聚类后的文本进行总结
 - 总结文本再次嵌入，并重复此过程直至不可行
 - 结果是多层次的树状结构，体现文档的组织
- **聚类的独特之处:**
 - 软聚类: 节点可以属于多个集群
 - 基于高斯混合模型 (GMM)
- **高维挑战 and UMAP降维:**
 - 高维向量嵌入对传统GMM构成挑战
 - 使用UMAP算法进行降维，创建层次化聚类结构

- **递归聚类:**
 - 如果总结文本超过令牌阈值，则在聚类内递归应用聚类
- **聚类数量的确定:**
 - 通过贝叶斯信息准则（BIC）确定最优聚类数量
- **高斯假设和实证观察:**
 - 虽然GMM的高斯假设可能不完全符合文本数据性质，但证明是有效的
 - 进行剥离实验比较GMM聚类和总结连续块的效果
- **折叠树方法概述:**
 - 将RAPTOR树压缩成单层，包括原树的所有节点
 - 用于简化搜索过程，同时比较所有节点
- **查询步骤:**
 1. 折叠RAPTOR树成单层集合C
 2. 计算查询嵌入与C中节点嵌入的余弦相似性
 3. 选取余弦相似度最高的前k个节点，不超过模型输入限制
- **性能测试:**
 - 在QASPER数据集的20个故事上测试
 - 折叠树方法比树遍历方法性能更好
 - 提供更大的灵活性和正确粒度级别的信息检索
- **折叠树方法的缺点:**
 - 需要对所有节点执行余弦相似性搜索
 - 可以使用FAISS等快速k最近邻库提高效率
- **实验配置:**
 - 使用2000最大令牌的折叠树方法，相当于检索前20个节点
 - 与UnifiedQA模型的实验提供了400个令牌的上下文
- **定性研究:**
 - 比较RAPTOR检索与DPR方法
 - 研究侧重于主题性多跳问题

- 使用1500字的《灰姑娘》故事进行分析
- RAPTOR提供比DPR更相关和全面的信息




图2：树遍历和折叠树检索机制的说明。树遍历从树的根节点开始，基于与查询向量的余弦相似度检索顶 k （此处为顶1）个节点。在每个级别上，它从上一层的顶 k 节点的子节点中检索顶 k 个节点。折叠树将树折叠成单个层并检索节点，直到达到基于与查询向量余弦相似度的阈值数量的节点。在两个说明中，执行余弦相似度搜索的节点都已被突出显示。




图3：查询方法的比较。使用不同top-k值的树遍历和具有不同上下文长度的收缩树对QASPER数据集中的20个故事进行测试的结果。使用具有2000个标记的收缩树产生最佳结果，因此我们使用这种查询策略进行主要结果。




图4：查询过程：RAPTOR如何为灰姑娘故事的两个问题（“故事的中心主题是什么？”和“灰姑娘如何找到一个幸福的结局？”）检索信息。高亮的节点表示RAPTOR的选择，箭头指向DPR的叶子节点。值得注意的是，RAPTOR的上下文通常包括DPR检索到的信息，无论是直接还是更高层次的摘要中。

4 实验

1. 数据集描述:

- **NarrativeQA**: 包含基于书籍和电影剧本全文的问答对，共1,572份文档。使用BLEU、ROUGE-L和METEOR指标衡量性能。
- **QASPER**: 包含5,049个问题，每个问题都探索NLP论文的全文信息。回答类型包括可回答/不可回答、是/否、抽象和提取。使用标准F1指标衡量准确度。
- **QuALITY**: 由多项选择问题组成，每个问题都附有平均约5,000词的上下文段落。数据集强调了对整篇文档进行推理的重要性。包含一个更具挑战性的子集QuALITY-HARD。

2. 控制基线比较:

- 使用SBERT、BM25和DPR作为检索模型，并结合GPT-3、GPT-4和UnifiedQA三种不同的语言模型进行比较。RAPTOR在QASPER数据集上的F1分数分别为53.1%、55.7%、36.6%，在所有三种语言模型上均优于BM25和DPR。

3. 与最先进系统的比较:

- RAPTOR结合GPT-4在QASPER上设定了新的基准，F1分数为55.7%，超过了CoLT5 XL的53.9%。
- 在QuALITY数据集上，RAPTOR配合GPT-4的准确度达到了82.6%，比之前的最好成绩高出了21.5%。
- 在NarrativeQA数据集上，RAPTOR的表现也优于多项指标，例如在ROUGE-L上超过BM25和DPR 7.3和2.7个百分点，在BLEU-1、BLEU-4和METEOR上也有所超越。

4. 实验结果摘要:

- RAPTOR在所有数据集上与任何检索器结合使用时，都一致地超过了相应的检索器。
- 当与SBERT结合使用时，RAPTOR表现最佳。

- RAPTOR利用中间层和聚类方法，能够捕捉从一般主题到特定细节的信息，从而贡献了其整体的强大性能。

4.1 树结构的贡献

- 假设：树结构上层节点对处理需要文本广泛理解的查询至关重要。
- 验证：通过定量和定性分析（见附录G），使用QuALITY数据集故事来验证上层节点的贡献。
- 发现：全树搜索策略优于仅关注特定层次的策略。
- 重要性：全树结构提供了从高阶主题到细节导向问题的全面信息。
- 附加信息：附录I提供额外故事和层次贡献的详细结果。

Model	ROUGE	BLEU-1	BLEU-4	METEOR
SBERT with RAPTOR	30.87%	23.50%	6.42%	19.20%
SBERT without RAPTOR	29.26%	22.56%	5.95%	18.15%
BM25 with RAPTOR	27.93%	21.17%	5.70%	17.03%
BM25 without RAPTOR	23.52%	17.73%	4.65%	13.98%
DPR with RAPTOR	30.94%	23.51%	6.45%	19.05%
DPR without RAPTOR	29.56%	22.84%	6.12%	18.44%

表1：带有和没有RAPTOR的NarrativeQA性能：在NarrativeQA数据集上使用统一QA-3B作为语言模型的各种检索方法（SBERT，BM25，DPR）的性能比较，以及带有和没有RAPTOR的基准检索方法。RAPTOR优于每个检索方法的基准。

Model	Accuracy (QuALITY)	Answer F1 (QASPER)
SBERT with RAPTOR	56.6%	36.70%
SBERT without RAPTOR	54.9%	36.23%
BM25 with RAPTOR	52.1%	27.00%
BM25 without RAPTOR	49.9%	26.47%
DPR with RAPTOR	54.7%	32.23%
DPR without RAPTOR	53.1%	31.70%

表2：质量与QASPER性能加上和不加RAPTOR：在各种检索方法（SBERT、BM25、DPR）的QuALITY和QASPER数据集上对性能进行比较，其中和RAPTOR一起使用，以及不加RAPTOR。使用统一QA-3B作为语言模型，RAPTOR在两个数据集上均优于每个检索方法的基准。

Retriever	GPT-3 F-1 Match	GPT-4 F-1 Match	UnifiedQA F-1 Match
Title + Abstract	25.2	22.2	17.5
BM25	46.6	50.2	26.4
DPR	51.3	53.0	32.1
RAPTOR	53.1	55.7	36.6

表3：使用三种不同的语言模型（GPT-3、GPT-4、UnifiedQA 3B）和各种检索方法对QASPER数据集上的F-1分进行受控比较。在标题和摘要仅用于上下文的情况下，“标题+摘要”一行反映了性能。RAPTOR在所有测试的语言模型中均优于已建立的基准BM25和DPR。具体来说，RAPTOR的F-1分数比DPR至少高1.8%，比BM25至少高5.3%。

Model	GPT-3 Acc.	UnifiedQA Acc.
BM25	57.3	49.9
DPR	60.4	53.9
RAPTOR	62.4	56.6

表4：使用不同检索方法对两种不同语言模型（GPT-3, UnifiedQA 3B）在QuALITY dev数据集上的准确性进行比较。RAPTOR在准确性上至少比BM25和DPR基准高出2.0%。

Model	F-1 Match
LongT5 XL (Guo et al., 2022)	53.1
CoLT5 XL (Ainslie et al., 2023)	53.9
RAPTOR + GPT-4	55.7

表5：QASPER数据集上各种模型在F-1分数匹配得分的结果。

Model	ROUGE-L	BLEU-1	BLEU-4	METEOR
BiDAF (Kočiský et al., 2018)	6.2	5.7	0.3	3.7
BM25 + BERT (Mou et al., 2020)	15.5	14.5	1.4	5.0
Recursively Summarizing Books (Wu et al., 2021)	21.6	22.3	4.2	10.6
Retriever + Reader (Izacard & Grave, 2022)	32.0	35.3	7.5	11.1
RAPTOR + UnifiedQA	30.8	23.5	6.4	19.1

表6：在NarrativeQA数据集上多个模型的性能对比，重点关注以下四个指标：ROUGE-L、BLEU-1、BLEU-4和METEOR。当RAPTOR与UnifiedQA 3B配对时，不仅超越了BM25和DPR等检索方法，而且在METEOR指标上还创造了新的最佳状态。

Model	Accuracy	
	Test Set	Hard Subset
Longformer-base (Beltagy et al., 2020)	39.5	35.3
DPR and DeBERTaV3-large (Pang et al., 2022)	55.4	46.1
CoLISA (DeBERTaV3-large) (Dong et al., 2023a)	62.3	54.7
RAPTOR + GPT-4	82.6	76.2

表7：整体测试集和更具挑战性的困难子集上的QUALITY数据集的准确性。GPT-4使用RAPTOR集创造了新的最佳状态。

5 结论

- RAPTOR：一种新型的基于树的检索系统，增强了大型语言模型的外部知识，提供了多层次的上下文信息。
- 技术：通过递归聚类和总结技术创建层次化的树结构。
- 性能：在问答任务上超越传统检索方法，设定新的性能基准。

6 可再现性声明

- 语言模型：RAPTOR实验中使用GPT-3、GPT-4及GPT-3.5-turbo模型，可通过OpenAI API访问；UnifiedQA可在Hugging Face上获取。
- 数据集：QuALITY、QASPER和NarrativeQA评估数据集公开可访问，保证实验可复制性。