

1. 论文名称: The Power of Noise: Redefining Retrieval for RAG Systems
2. 论文团队: 罗马第一大学
3. github: <https://github.com/florin-git/The-Power-of-Noise.git>

Abstract

1. 研究主题:
 - 检索增强生成 (Retrieval-Augmented Generation, RAG) 系统
2. 研究背景:
 - RAG系统通过信息检索 (IR) 阶段的外部数据检索, 提高了传统大型语言模型 (LLMs) 的生成能力。
 - 标准LLMs受限于其预训练知识和有限的上下文窗口。
3. 研究差异:
 - 以往研究集中在RAG系统内LLMs的生成性方面。
 - 本研究填补了IR组件对RAG系统影响分析的空白。
4. 研究内容:
 - 分析了RAG提示公式的有效检索器特征。
 - 关注了应检索的文档类型。
5. 研究方法:
 - 评估了文档与提示的相关性、文档的位置和数量等因素对上下文的影响。
6. 研究发现:
 - 包括不相关文档可能意外提高超过30%的准确率。
 - 这一发现与最初预期的质量下降假设相矛盾。
7. 研究意义:
 - 需要开发专门的方法来满足将检索与语言生成模型结合的特定需求。
 - 结果为将来的研究奠定了基础, 强调了开发集成检索与语言生成模型策略的必要性。

1 Introduction

1. 引言:
 - 背景: 大型语言模型 (LLMs) 在多种任务中表现出色, 但处理大文本时存在局限性, 这可能导致对预训练知识的过分依赖, 以及生成不准确或无意义信息的概率增加。
 - 解决方案: 检索增强生成 (RAG) 系统通过整合信息检索 (IR) 组件, 提高了LLMs生成回应的准确性, 这个组件在回应生成过程中动态地检索相关外部信息。
2. 研究问题:

- 核心问题：检索器需要具备哪些关键特征才能优化RAG系统的提示构建？当前的检索器是否理想？
- 文档类型：研究关注三种文档类型——相关的、关联的和无关的，并分析它们如何影响检索结果。

3. 研究分析：

- 发现：关联文档比无关文档更有害。意外的是，包括噪声（无关）文档可以提高高达35%的性能。
- 意义：这表明传统的检索技术可能不适合新范式，需要开发专门的方法来满足集成检索与语言生成模型的需求。

4. 研究贡献：

- a) 进行了首次综合研究，集中于检索文档如何影响RAG框架。
- b) 发现与常识相反的结果：在RAG系统中，无关文档比关联文档更有益。
- c) 提出了利用这一现象的策略，并强调需要重新考虑信息检索策略。

2 相关工作

2.1 生成性语言模型

- 现代LLM的起点可追溯至“Attention Is All You Need”一文，提出了Transformer架构，使用注意力机制而非循环层。
- BERT（2018年）引入了深度双向、无监督的语言表示，标志着对文本中上下文理解的重大进步。
- GPT系列的发展代表了变换器基模型的进化，尤其是GPT-3在模型规模和能力上的进一步提升。
- 特别化模型和变体的涌现，如T5和XLNet，都在Transformer架构上有所扩展。

2.2 信息检索

- IR的起源聚焦于文本系统，采用向量空间模型（VSM）和词频-逆文档频率（TF-IDF）等传统方法。
- IR领域的一项重大演变是稀疏检索器与密集检索器之间的区分。
- 密集检索器利用深度学习产生的低维密集向量表示，与稀疏检索器如VSM和TF-IDF相对立。

2.3 检索和生成

- RAG将检索和生成模型的优点结合起来，代表了机器学习中的重大转变。
- RAG的概念最初来源于其他工作，但在一篇引入了密集通道检索器与序列到序列模型相结合的文章中被推广开来。
- 本文的目的是提供使用检索器模块在RAG系统中的第一个全面分析，研究文件的位置、类型和数量等关键因素的影响。

3 RAG

- 概述：RAG提供了一个强大的框架，可成功应用于多种问题和下游任务，尤其是在问答方面。

3.1 开放域问答（OpenQA）

- 定义：指提供准确且情境相关的回答的任务，不限于特定领域或预定义数据集。
- 方法：通过从大型文档集中检索信息来找到问题的答案。
- 结构：通常涉及检索器和推理器（生成器）两步架构，通过分阶段处理信息检索、找到正确文档集和合成答案来应对OpenQA的复杂性。

3.2 检索器

- 作用：在OpenQA中扮演关键角色，旨在从文档集中找到足够小的子集来帮助推理器正确回答问题。
- 密集检索器：由于其在处理复杂和多样化查询方面的有效性而变得突出。
- 过程：使用类似BERT的Transformer编码器将文本数据转换为高维向量表示，然后通过点积（dot product）等相似性度量方式来评分和排序文档。

3.3 推理器（Reasoner）

- 定义：在RAG中，推理器通常是一个生成性的大型语言模型（LLM），负责生成连贯、情境相关且语义准确的文本作为查询的回应。
- 功能：生成语言模型通过预测下一个词汇的概率分布来操作，这个分布是基于之前的词序列。
- 数学表示：对于词序列 $w_1, w_2, \dots, w_n$ ，生成语言模型旨在最大化这个序列的似然概率，使用概率链式规则表达： $P(w_1, w_2, \dots, w_n) = \prod_{i=1}^N P(w_i | w_1, w_2, \dots, w_{i-1})$
- RAG中的应用：在RAG中，生成语言模型接受查询 q 和检索到的文档集 D_r 作为输入，并通过顺序预测序列中的下一个词汇来生成回应。
- 概率公式：在RAG框架下，生成回应的概率可以表示为： $P_{rag}(y|q) = \prod_{i=1}^N \sum_{d \in D_r} p_n(d|q) p_{\theta}(y_i|q, d, y_{i-1})$ ，其中 $p_n(d|q)$ 是检索组件为高分文档提供的概率分布， $p_{\theta}(y_i|q, d, y_{i-1})$ 是由 θ 参数化的概率分布，它基于先前生成的词汇、查询和检索到的文档来生成当前词汇。

4 实验方法论

4.1 自然问题数据集（Natural Question Dataset）

- 介绍：自然问题（NQ）数据集是一个大规模的实际查询集合，源自Google搜索数据。
- 结构：包括用户查询和包含答案的对应Wikipedia页面。
- 目的：旨在促进自然语言理解和开放域问答研究。
- NQ-open数据集：是NQ数据集的子集，通过去除将答案与特定Wikipedia段落链接的限制，提供更一般的信息检索场景。
- 细节：最终数据集包含21,035,236个文档，训练集有72,209个查询，测试集有2,889个。

4.2 文档类型

- 分类：根据与查询的相关性和关系，将文档分为四种类型，每种类型用一个独特的符号表示：
 -  Gold Document：NQ数据集中特定包含答案的Wikipedia段落。
 -  Relevant Documents：类似于gold document，包含正确答案并对回答查询有实际帮助的文档。
 -  Related Documents：与查询语义上相似但不包含正确答案的文档。
 -  Irrelevant Documents：既不相关也不包含答案的文档，用于评估模型处理完全无关信息的能力。

4.3 文档检索

- 方法：采用了RAG设置中的典型两步法，第一步使用基于BERT的密集检索器Contriever作为默认检索器。
- 训练：Contriever无监督训练，使用对比损失。
- 效率：为提高21百万文档的相似性搜索效率，采用FAISS IndexFlatIP索引系统。
- 文档和查询嵌入：通过平均模型最后一层的隐藏状态来获得。

4.4 LLM输入

- 过程：检索器接收查询后，根据给定的相似性度量选择顶部k个文档，这些文档与任务指令和查询一起构成LLM生成响应的输入。
- 数据集结构：NQ-open数据集只包含答案不超过五个词的查询。
- 任务：LLM的任务是从提供的文档中提取一个最多五个词的回答。
- 输入模板：输入模板以任务指令（斜体）开始，接着是上下文（选择的文档），最后是查询。如图1所示，查询紧跟文档之后，与方法论21所述的方法一致。




Figure 1: Example LLM input with an erroneous output, highlighted in red. The input consists of an *italicized task instruction*, followed by the context (documents), and the query. The LLM's response is marked under 'Answer'. The gold color highlights both the gold document and the correct answer, "Lando Calrissian", indicating the expected source and content of the accurate response.

- 示例：提供了一个只包含Gold Document的LLM输入示例，展示了输入格式和预期的输出。

4.5 测试的LLMs

- 实验设计：在实验中考虑了几种LLMs，所有模型都采用了贪婪生成方法，并且最大回应长度限制为15个词。
- 模型量化：由于内存和计算资源的限制，实现了模型量化策略，将所有模型减少到4比特表示。
- 测试模型：
 - Llama2：拥有7B参数，展示了最先进的性能。
 - Falcon：同样是7B参数模型，基于大型过滤和去重的RefinedWeb数据集训练。
 - Phi-2：参数最少的模型（2.7B参数），但由于预训练在“教科书质量”数据上，其性能与其他模型相当。
 - MPT：同样拥有7B参数，使用ALiBi注意力机制，可处理几乎无限的上下文长度。

4.6 准确性

- 数据集允许范围：NQ-open数据集允许每个查询有多种潜在答案。
- 评估策略：通过检查LLM产生的响应中是否包含至少一个预定义的正确答案来评估准确性。
- 准确性测量：LLM响应的正确性是基于答案是否出现来以二进制方式判断的。
- 评估挑战：评估策略面临挑战，特别是在涉及日期表示或传达相同含义的不同措辞时。

- 示例问题：如果LLM对查询生成的回应是“Roosevelt”，而确定的正确答案是“President Roosevelt”，则根据当前的评估方案，这个回应会被认为是不准确的。