

1. 论文名称: Improving Medical Reasoning through Retrieval and Self-Reflection with Retrieval-Augmented Large Language Models
2. 论文链接:
3. github: <https://github.com/dmis-lab/self-biorag>

Abstract

- **项目名称:** Self-BioRAG
- **目的:** 解决生物学领域中的多样化挑战
- **背景:** 现有的大型语言模型（LLM），如GPT-4，在多种任务上取得进展，但在领域特定问题上存在泛化能力不足。
- **方法:**
 - 开发了检索增强生成（RAG）方法
 - 提出Self-BioRAG框架，专注于生成解释、检索特定领域文档
 - 训练了Self-BioRAG，使用了84k过滤后的生物学指令集和定制反射性标记
- **关键组件:**
 - 检索器
 - 领域相关文档库
 - 指令集
- **性能:**
 - 在三个主要医学问答基准数据集上，与参数大小为7B或更小的模型相比，平均性能提高了7.2%。
- **结论:**
 - Self-BioRAG能像医学专家一样理解和回答问题
 - 发布数据和代码以增强生物学和临床领域的能力
- **模型权重:**
 - 发布了7B和13B的模型权重

1 Introduction

1.1 引言和背景

- **现状:** 最新的大型语言模型（LLM），例如ChatGPT、GPT-4和BARD，在多项挑战中取得了类似专家的成就。
- **问题:** 尽管它们在多种任务中表现出高效率和多功能性，但在全面覆盖用户依赖的信息（如患者报告）时存在不足，可能导致错误信息的生成，这被称为幻觉问题。

- **现有方法:** 检索增强生成 (RAG) 方法通过提供支持事实来增强LLMs生成的响应的可解释性。




图1: 三种框架的比较: 使用语言模型 (LM) 生成、使用LM增强检索的生成 (RAG) 以及我们的Self-BioRAG。(A) 显示了LM的序列到序列生成过程。(B) RAG框架首先从大规模语料库 (如PubMed Central) 中查找相关文档, 然后基于这一事实内容提供答案, 以解决稀缺知识不足的问题。(C) 最初, 我们的特定领域指令微调模型预测是否需要检索。如果查询不需要任何检索知识 (事实内容), 则直接预测答案。然而, 如果查询需要检索知识, Self-BioRAG使用特定领域的检索器 (在我们的情况下是MedCPT) 来检索相关文档。在检索到k个证据后, 模型为查询选择最相关的证据。最终, 我们使用语言模型来基于选定的证据和编码的知识来选择最佳证据并生成答案。

1.2 Self-BioRAG框架

- **目标:** 提出一个新框架Self-BioRAG, 专门训练于生物医学和临床文本指令, 能够灵活地应对相关指令, 保持生成质量和推理能力的同时, 加入按需检索和自我反思能力。
- **核心组件:**
 - 生物医学指令集
 - 生物医学检索器
 - 自我反思语言模型
 - 领域特定指令调优语言模型
- **构建方式:** 结合了多个数据集, 包括分布式MoL指令集、MedInstruct和自创的18k生物医学和临床指令。

1.3 贡献和成果

1. **框架介绍:** 介绍了一个全面训练于生物医学和临床指令的Self-BioRAG框架。
2. **领域特定组件的证明:** 证明了检索器、文档和指令集这样的领域特定组件对于满足领域相关指令至关重要。
3. **性能验证:** 在三个生物医学问答开放域数据集中, Self-BioRAG的性能显著超过了参数大小为7B或更小的开放基础LLM和RAG方法, 平均改进了7.2%。

4. **资源共享**: 发布了用于Self-BioRAG的生物学指令集、训练组件的代码以及模型权重（7B和13B），以增强其在生物学和临床领域的能力。

2 Background

2.1 专有与开放语言模型

- 指令作为语言模型执行特定任务的指南，专有语言模型（如InstructGPT和ChatGPT）在指令调优方面取得了显著优势。

2.2 奖励策略学习

- 采用来自人类反馈的强化学习训练的专有语言模型，在执行简单指令（例如翻译、代码生成和问答）方面表现出色。
- Self-RAG通过使用反射性令牌来提供成本效益高的奖励策略，这种批评性语言模型能够判断任务是否需要检索，评估检索内容的适用性。

2.3 检索增强生成

- 检索增强生成（RAG）通过为语言模型提供输入上下文，显著提高了知识密集型任务和开放域问答的性能。
- 在特定领域，如生物学或临床领域，通用的检索方法可能不适用，因此Self-BioRAG采用了针对特定领域的检索方法，检索与预期领域相符的有意义的上下文。

3 Self-BioRAG

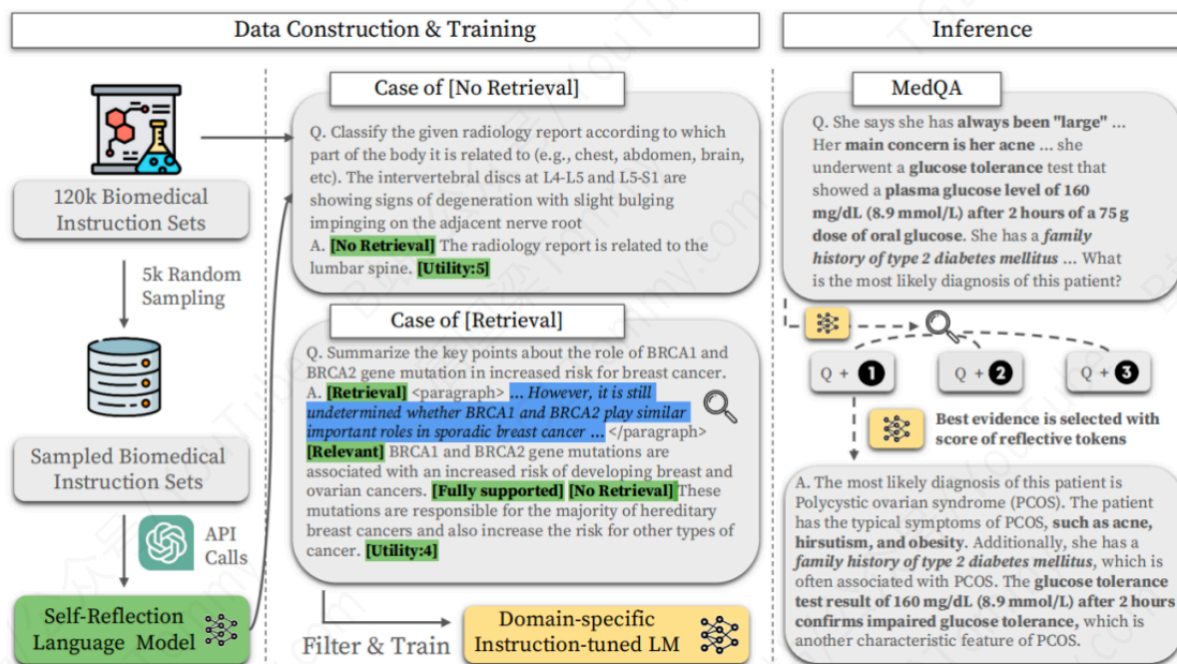


图2：我们的Self-BioRAG过程的概述：数据构建、训练和推理自我反思语言模型（批评LM C）和特定领域指令调谐语言模型（生成器LM M）。我们使用两个现成的指令集（Mol-Instructions（Fang等人，2023年）和MedInstruct（Zhang等人，2023年））和一个自我生成的生物医学指令集来构建120万个生物医学指令集。我们首先通过调用GPT-4 API调用采样5千条指令来生成反射令牌，然后使用这些指令训练批评LM C。使用训练好的批评LM C，我们过滤掉误判的反射令牌，例如[继续生成]。我们保留带有预定义的反射令牌注释的8.4万个指令集来训练生成器LM M。请注意，批评LM C仅用于注释用于过滤指令集以训练生成器LM M的反射令牌。训练后，模型M可以预测是否使用检索方法，并将证据和编码知识的结果结合起来回答问题。我们使用MedQA（Jin等人，2021年）测试样本来了解我们的Self-BioRAG如何工作。

3.1 生物医学教学数据集

- **创建过程:** 利用各种生物医学组件创建Self-BioRAG框架。
- **生物医学指令数据集:** 使用三个包含生物医学指令的数据集来训练与生物医学文本人类意图对齐的语言模型。合计构建了120k生物医学指令集以处理多样化的任务。

3.2 生物医学检索器

- **生物医学检索器:** 使用MedCPT检索器，该检索器在生物医学和临床领域检索相关文档方面效果显著。检索器利用PubMed摘要、PMC全文、临床指南和英文医学教科书中的数据。

3.3 自我反思语言模型（批评语言模型）

- **数据构建:** 收集了120k生物医学指令集，并随机抽样5k例子训练批评性语言模型C。
- **训练过程:** 使用四种反射性tokens训练批评性语言模型C，它通过预测这些tokens来学习。
- **注释指令集:** 使用训练好的语言模型C来注释整个指令集，并筛选出预测错误的反射性tokens的实例。

3.4 领域特定指令调优的语言模型（生成器语言模型）

- **数据构建:** 使用批评性语言模型C和MedCPT检索器，从生物医学上下文中检索top-k证据，并用来训练生成器语言模型M。
- **生成器语言模型M:** 使用预先定义的反射性tokens注释的84k过滤后的生物医学指令集来训练。
- **目的:** 批评性语言模型C仅用于注释反射性tokens，以生成用于训练生成器语言模型M的生物医学指令集。

Self-BioRAG的推理过程

- **例子:** 展示了一个MedQA示例，说明Self-BioRAG离线推理过程。
- **评分函数:** 使用加权的方式，结合反射性tokens，计算评分S，该评分用于从top-k检索文档中选择最佳证据。
- **公式:** $S(\text{Critique}) = \sum_{G \in G} w^G s^G$ ，其中 s^G 表示最期望的反射性tokens $\hat{r}$ 的生成概率， w^G 表示为 s^G 提供权重的超参数。
- **应用:** Self-BioRAG能够在不需要额外训练的情况下，有条件地生成文本，这可能需要在多个偏好之间进行权衡。
- **结果:** 生成器模型M生成文本，识别问题中的线索，检索必要的事实内容，并像医生处理此类案例一样，用编码知识做出回应。

Type	Input	Output	Definitions
RET	$x/x, y$	{yes, no, continue}	Decides when to retrieve using R
REL	x, e	{ relevant , irrelevant}	e provides useful information to solve x
SUP	x, e, y	{ fully supported , partially supported, no support}	All of the verification-worthy statement in y is supported by e
USE	x, y	{5, 4, 3, 2, 1}	y is a useful response to x

表3. 在Self-BioRAG中使用的反射令牌，**x**、**y**和**e**分别表示输入、输出和证据。具体强调的反射令牌（加粗）在数据构造期间是可取的，因为它们有助于保留现有的指令数据。

4 实验细节

- **基准评估:**
 - 对Self-BioRAG进行了细调并评估了下游任务性能。
 - 实验涉及旨在评估生物医学和临床知识编码的多项选择问答基准。
 - 使用了三个数据集：MedQA、MedMCQA和MMLU。
- **基线:**
 - 将Self-BioRAG与专有基础、开放基础以及带检索增强的语言模型进行了比较。
 - 报告了Med-PaLM、GPT-3.5和GPT-4基础分数作为基准的上界。
 - 报告了特定领域（如生物医学和临床）细调的模型，如Alpaca和Flan-T5。
- **训练与推理设置:**
 - Self-BioRAG用84k过滤的生物医学指令集训练，这些指令集通过训练有素的批评性语言模型（LM）过滤得到。
 - 使用Self-RAG批评性LM作为基础模型，并用GPT-4 API调用注释的5k采样指令集进行微调。

- 使用MedCPT检索器，从PubMed摘要、PMC全文、临床指南等来源检索文档。
- **推理过程:**
 - 使用vllm加速推理。
 - 在解码时为反射性tokens分配相同的权重。
 - 采用默认的自适应检索，它可以动态决定何时进行检索。
- **性能:**
 - Self-BioRAG在处理问题、检索事实内容和使用编码知识响应方面表现类似于医生的方式。

5 结果和分析

5.1 实验结果

- Self-BioRAG在所有三个生物学基准数据集（MedQA、MedMCQA和MMLU-Med）中都优于其他7B或更小参数的开放基础语言模型（LM）。
- Self-BioRAG在使用反射性代币分析检索到的所有证据方面表现更好，可以优先考虑重要的证据。
- 即使Self-RAG在LLaMA2上进行了微调，但它在生物学基准数据集上的泛化性较差。
- 提供了13B参数的Self-BioRAG模型的性能以证明框架工作在其他模型参数上的有效性。

Model	Params.	Open-domain Biomedical Benchmark				
		MedQA (Acc.)	MedMCQA (Acc.)	MMLU-Med (Acc.)	Average	
Proprietary LM						
Med-PaLM (Singhal et al., 2022)	540B	60.3	56.5	75.6	64.1	
GPT-3.5 (OpenAI, 2023a)	-	53.6	51.0	67.3	57.2	
GPT-4-base (OpenAI, 2023b)	-	86.1	73.7	89.9	83.2	
Open LM						
Alpaca (Taori et al., 2023)	7B	23.6	30.4	34.4	29.5	
FLAN-T5 (Chung et al., 2022)	3B	36.1	20.0	44.2	33.4	
Galactica (Taylor et al., 2022)	6.7B	29.5	32.7	39.4	33.9	
MEDITRON (Chen et al., 2023)	7B	36.5	37.1	41.1	38.3	
LLaMA2 (Touvron et al., 2023)	7B	35.2	36.3	46.3	39.3	
Open LM + Retrieval						
RAG	7B	36.2	38.3	47.7	40.7	
Self-RAG (Asai et al., 2023)	7B	31.2	36.5	45.7	37.8	
Self-BioRAG (Ours)	7B	43.6	42.1	53.9	46.5	
Self-BioRAG (Ours)	13B	48.6	44.0	57.2	49.9	

表4. 生物学基准数据集的实验结果。我们使用3-shot示例作为语言模型解决基准实例的指导。这些示例使用k-最近邻 (Guo等人, 2003) 从每个训练数据集中选择。由于MMLU数据集缺乏训练数据, 我们使用MedPALM附录中详细说明的相同示例 (Singhal等人, 2022)。GPT-3.5和GPT-4-base模型的得分来自以下论文 (Nori等人, 2023)。在RAG设置上进行推理时, 我们使用生物学语料库 (如PubMed、PMC、CPG和教科书) 作为证据。对于参数大小为7B或更小的模型, 最佳得分用粗体突出显示。

5.2 分析

- 通过逐步添加生物学组件到Self-RAG中, 来展示领域适应性组件在性能提升中的作用。
- 最有效的方法是收集和处理生物学指令集, 以创建批评性语言模型和生成语言模型。
- 在生物学语料库中, 检索证据的使用有助于解决开放域问答基准测试。
- Self-BioRAG在使用检索证据的情况下, 只检索了少部分证据来解决问题 (MedQA 12%, MedMCQA 8%, MMLU-Med 11%)。
- 三种不同的实验设置表明, 检索相关文档确实有助于解决基准数据集问题, 尤其是在采用自适应检索的情况下。
- 自适应检索默认动态决定是否需要根据问题检索证据, 并提取生物学语料库中的top-10证据。

Experiment Detail	MedQA (Acc.)	MedMCQA (Acc.)	MMLU-Med (Acc.)	Average
Self-RAG (Asai et al., 2023)	31.2	36.5	45.7	37.8
+ Biomedical Corpora	33.5	38.9	46.7	39.7 (+1.9)
+ MedCPT Retriever	35.6	40.1	49.3	41.7 (+3.9)
+ Biomedical Instruction Sets	43.6	42.1	53.9	46.5 (+8.7)

Table 5. Effect of each domain-adaptation component.

Methods	MedQA (Acc.)	MedMCQA (Acc.)	MMLU-Med (Acc.)	Average
Only [No Retrieval]	39.7	41.9	52.8	44.8
Only [Retrieval]	40.1	47.2	51.3	46.2
Adaptive Retrieval (Ours)	43.6	42.1	53.9	46.5

Table 6. Effect of adaptive retrieval in Self-BioRAG. ‘Only [No Retrieval]’ refers to not retrieving any evidence, and ‘Only [Retrieval]’ refers to forcing the retrieval of top 10 evidences.

MedQA Dataset

Query: A 27-year-old woman presents to the office with **concerns about her long struggle with her physical appearance since adolescence**. She says **she has always been “large”** and was constantly targeted by her classmates and coworkers for being so. **Her main concern at the moment is her acne and unwanted facial hair** on her upper lip, for which she often visits a local spa. She has tried numerous diet plans, exercise regimens, and cosmetic products with little to no effect. Recently, **she underwent a glucose tolerance test that showed a plasma glucose level of 160 mg/dL (8.9 mmol/L) after 2 hours of a 75 g dose of oral glucose**. **She has a family history of type 2 diabetes mellitus** and a menstrual cycle that occurs every 45 days. Her pulse is 72/min and the blood pressure is 138/80 mm Hg. On physical examination, her height is **160 cm (5 ft 3 in)** and **her weight is 85 kg (187 lb)**, and **she has severe inflammatory acne over the cheeks and forehead and dark coarse hairs on the back**. What is the most likely diagnosis of this patient?

Option A: Hypothyroidism

Option B: Idiopathic hirsutism

Option C: Polycystic ovarian syndrome (PCOS)

Option D: Ovarian hyperthecosis

Evidence: *Early Clinical Expressions of Insulin Resistance: The Real Enemy to Look For. Today, a very common clinical scenario is a 17-year-old female with a family history of type 2 diabetes mellitus (T2DM) and hypertension in her mother and two first-degree relatives. Three years ago she was diagnosed with polycystic ovarian syndrome (PCOS). She is overweight with her body weight increasing 10 kg in the last 2 years. Additionally, she has acanthosis nigricans (AN) in the axillae and knuckles. Blood tests were unremarkable with a fasting plasma glucose value of 82 mg/dl and an HbA1c of 5.0%.*

Prediction: The most likely diagnosis of this patient is Option C: Polycystic ovarian syndrome (PCOS). **The patient has the typical symptoms of PCOS, such as acne, hirsutism, and obesity**. Additionally, **she has a family history of type 2 diabetes mellitus**, which is often associated with PCOS. **The glucose tolerance test result of 160 mg/dL (8.9 mmol/L) after 2 hours confirms impaired glucose tolerance**, which is another characteristic feature of PCOS.

表7. 使用MedQA数据集中证据进行Self-BioRAG预测的案例报告。已检索的证据以斜体形式书写。蓝色文本包含与已检索证据中的关键信息相关的段，而红色文本则由与模型参数知识相关的段组成。我们的模型利用这两种类型的段来解决给定查询。

6 结论

- **Self-BioRAG框架介绍:** 介绍了能够泛化到生物医学和临床指令领域的Self-BioRAG框架。这个框架提高了生成能力，便于按需检索事实内容，并能自我评估生成的理由。
- **性能提升:** Self-BioRAG在三个广泛使用的生物医学和临床领域的多项选择问答基准数据集上实现了7.2%的绝对性能提升，与开放基础7B模型的最新艺术状态模型相比。
- **领域特定组件的必要性:** 论文证明了检索器、领域相关文档库、自我反思模型和生成器模型这些领域特定组件的必要性，以解决与领域相关的指令。
- **多样化分析:** 提供了多样化的分析，包括Self-BioRAG从医学教科书中检索的证据比例大于其他语料库，以及Self-BioRAG能够根据指令和问题区分何时检索证据。
- **证据的辅助作用:** 来自生物医学语料库的证据确实有助于补充有限的知识。
- **闭域问答数据集的局限性:** 在如PubMedQA这样的闭域问答数据集中观察到局限性，由于过多噪音信息，检索到的证据可能是错误的。

- **未来工作:** 未来的工作将探索领域特定的反射性代币，这些代币可能增强评估和生成能力，并结合领域知识。而不是评估多项选择问答，未来的目标是生成形式文本或调整模型以进行聊天对话。