

1. 论文名称: RAGAS: Automated Evaluation of Retrieval Augmented Generation
2. 团队: 卡迪夫大学
3. github: <https://github.com/explodinggradients/ragas>

Abstract

研究主题: RAGAS框架

研究目的: 为检索增强生成 (RAG) 管道提供无需参考的评估框架。

研究对象: RAG系统, 包括检索模块和基于大型语言模型 (LLM) 的生成模块。

主要挑战: 评估RAG架构时需要考虑多个维度, 包括:

1. 检索系统识别相关上下文段落的能力。
2. LLM利用这些段落的能力。
3. 生成结果的质量。

研究成果: 提出了RAGAS, 一套可以用来评估上述维度的指标, 无需依赖人类注释。

意义: 该框架有助于加快RAG架构的评估周期, 对于LLM的快速采用非常重要。

1 Introduction

- **语言模型简介:**
 - 语言模型 (LMs) 能够捕捉大量关于世界的知识, 允许在不访问外部资源的情况下回答问题。
 - LMs作为知识库的概念在BERT出现后不久就形成, 并随着更大型LMs的引入而变得更加确立。
- **大型语言模型 (LLMs) :**
 - 最新的LLMs能够捕捉足够的知识来与人类在各种问答基准测试中的表现相匹敌。
 - 使用LLMs作为知识库的想法存在两个基本限制: 一是不能回答训练后发生的事件的问题; 二是即使是最大的模型也难以记住训练语料中很少提及的知识。
- **检索增强生成 (RAG) :**
 - 标准的解决方案是依赖RAG, 通过从语料库检索相关段落并将这些段落与原始问题一起提供给LM来回答问题。
 - 最初的方法依赖于专门的LMs进行检索增强语言建模, 但最近的研究表明, 向标准LM的输入中简单地添加检索文档也可以工作。
- **RAG系统的评估:**
 - RAG系统的实用性很明确, 但其实现需要大量调优。
 - RAG系统通常通过测量某些参考语料库上的困惑度来评估, 但这样的评估并不总是预示着下游性能。
 - 通常的评估策略依赖于LM概率, 这对于某些封闭模型 (如ChatGPT和GPT-4) 是不可访问的。
- **RAGAS框架:**

- 为解决上述问题，论文提出了RAGAS框架，用于自动评估检索增强生成系统。
- RAGAS专注于不一定有参考答案可用的设置，希望除了检索段落的有效性的有用性外，还能估计正确性的不同代理。
- RAGAS框架与构建RAG解决方案的最广泛使用的框架llama-index和Langchain集成，使开发者能够轻松将RAGAS集成到他们的标准工作流程中。

2 Related work

- 使用LLMs估计忠实度：
 - 研究了在LLM生成的回答中检测幻觉的问题。
 - 使用少量提示预测事实性的策略，但现有模型在使用标准提示策略时检测幻觉上存在挑战。
 - 其他方法依赖于将生成的回答与外部知识库的事实链接，但这不总是可行的。
- 检测策略：
 - 检查个别词汇的概率分配，估计模型在事实性答案上的信心程度。
 - BARTScore通过观察生成文本的条件概率来评估事实性。
 - Azaria和Mitchell（2023年）提出训练一个监督分类器，使用LLM的隐藏层权重来预测语句的真实性。
- 自动评估文本生成系统：
 - LLMs也被用来自动评估生成文本片段的其他方面，如流畅性。
 - 使用特定提示来评估ChatGPT生成答案的特定方面，提供0到100之间的分数。
 - 研究也集中在使用LLM选择最佳答案，这需要注意答案呈现的顺序可能会影响结果。
- 评估标准：
 - 大多数方法依赖于一个或多个参考答案的可用性，例如BERTScore和MoverScore使用上下文感知嵌入来比较生成答案和参考答案之间的相似性。
 - BARTScore使用参考答案计算精确度（生成答案与参考答案的匹配程度）和召回率（生成参考答案的概率）。

3 Evaluation Strategies

3.1 评估策略简介

- 标准的RAG环境中，系统首先检索与问题 q 相关的上下文 $c(q)$ ，然后使用检索到的上下文生成答案 $a_s(q)$ 。
- 构建RAG系统时，常常没有人工注释的数据集或参考答案可用，因此关注完全自足和无需参考的指标。

3.2 质量方面

- 三个重要质量方面：忠实度、答案相关性和上下文相关性。

- **忠实度**：回答应基于给定上下文，避免幻觉并确保检索上下文可以作为生成答案的依据。
- **答案相关性**：生成的答案应该针对提供的实际问题。
- **上下文相关性**：检索到的上下文应该尽可能专注，包含尽可能少的无关信息。

3.3 自动化度量方法

- 使用LLM的提示来全自动化地测量这些质量方面。
- 实验中使用的是通过OpenAI API提供的gpt-3.5-turbo-16k模型。

3.4 忠实度量

- 如果答案 $a_s(q)$ 中的声明可以从上下文 $c(q)$ 推断出来，则称答案对上下文是忠实的。
- 首先使用LLM提取一组声明 $S(a_s(q))$ ，目的是将较长的句子分解为更短、更聚焦的断言。
- 用于提取声明的提示：“给定一个问题和答案，从给定答案中的每个句子创建一个或多个声明。”
- 使用验证函数 $v(s_i, c(q))$ 确定 S 中的 s_i 是否可以从 $c(q)$ 推断出来。
- 忠实度得分 F 的计算方式是 $F = \frac{|V|}{|S|}$ ，其中 $|V|$ 是LLM支持的声明数量， $|S|$ 是声明的总数。

举例讲解：

场景设定：

想象我们正在使用一个语言模型来回答关于“北京故宫”的问题。问题 q 是：“故宫是在哪个朝代建成的？”系统生成的答案 $a_s(q)$ 是：“故宫建成于明朝，由朱元璋下令建造。”

步骤 1：提取声明

从生成的答案 $a_s(q)$ 中提取一组声明 $S(a_s(q))$ 。在这个例子中，可能的声明有：

1. 故宫建成于明朝。
2. 故宫是朱元璋下令建造的。

步骤 2：使用LLM分解断言

使用LLM将答案中的每个句子分解成独立的、更精确的断言。我们可能会用下面的提示去做这件事：

给定一个问题和答案，请从给定答案的每个句子中创建一个或多个声明：

问题：故宫是在哪个朝代建成的？

答案：故宫建成于明朝，由朱元璋下令建造。

步骤 3：验证声明

使用LLM对每个声明进行验证，看看这些声明是否可以从给定的上下文中推断出来。这里的上下文 $c(q)$ 可能是关于故宫历史的正式文档或可靠来源的历史记录。

验证提示可能是：

请考虑给定的上下文和以下声明，然后确定它们是否得到上下文中信息的支持。在得出结论（是/否）之前，请为每个声明提供简短的解释。请按照指定格式为每个声明最终得出结论。不要偏离指定的格式。

声明：故宫建成于明朝。

声明：故宫是朱元璋下令建造的。

...

步骤 4：计算忠实度得分

根据LLM的验证，计算得到支持的声明数 $|V|$ 和总声明数 $|S|$ 。在我们的例子中，如果历史记录证实了这两个声明，那么我们会两个支持的声明。

最后的忠实度得分 F 计算为 $F = \frac{|V|}{|S|}$ 。在这个例子中，如果两个声明都被验证为正确（即，历史记录确实表明故宫是明朝建成的，并且是由朱元璋下令建造的），那么 $|V| = 2$ 并且 $|S| = 2$ ，所以忠实度得分 F 为 1 或者 100%。

这个忠实度得分表明生成的答案在历史上是准确的，完全基于正确的上下文信息。如果在验证过程中发现某些声明并不准确，或者上下文中没有足够的信息来支持这些声明，那么 $|V|$ 将会小于 $|S|$ ，得分会相应降低。

3.5 答案相关性

- 答案 $a_s(q)$ 的相关性是指它是否直接以恰当的方式回答了问题 q 。
- 评估答案相关性不考虑事实性，但会惩罚答案不完整或包含冗余信息的情况。
- 为了估计答案相关性，通过LLM生成 n 个可能的问题 q_i ，基于答案 $a_s(q)$ ，使用以下提示："Generate a question for the given answer: answer: [answer]"。
- 使用OpenAI API提供的text-embedding-ada-002模型获取所有问题的嵌入，计算 q_i 与原始问题 q 之间的相似性，作为余弦相似度。
- 答案相关性得分 AR 通过公式 $AR = \frac{1}{n} \sum_{i=1}^n sim(q, q_i)$ 计算，此指标评估生成答案与初始问题对齐的程度。

举例讲解：

场景设定：

想象我们正在使用一个语言模型来回答关于“太阳系”的问题。问题 q 是：“太阳系中最大的行星是哪一个？”系统生成的答案 $a_s(q)$ 是：“木星是太阳系中最大的行星，其体积和质量均是最大的。”

步骤 1：生成潜在问题

我们要求LLM基于答案 $a_s(q)$ 生成一系列潜在的问题 q_i 。比如，我们可以给LLM以下提示：

为给定答案生成一个问题：

答案：木星是太阳系中最大的行星，其体积和质量均是最大的。

LLM可能会生成如下潜在问题：

1. 太阳系中哪个行星最大？
2. 哪个行星在体积和质量上是太阳系中的领导者？
3. 太阳系中最重的行星是哪一个？

步骤 2：获取问题嵌入

使用OpenAI API提供的text-embedding-ada-002模型获取原始问题 q 以及每个潜在问题 q_i 的嵌入。

步骤 3：计算相似度

对于每个潜在问题 q_i ，计算其与原始问题 q 在嵌入空间中的余弦相似度 $\text{sim}(q, q_i)$ 。

步骤 4：计算答案相关性得分

答案相关性得分 AR 通过下面的公式计算：

$$AR = \frac{1}{n} \sum_{i=1}^n \text{sim}(q, q_i)$$

其中 n 是生成的潜在问题的数量。

例子中的计算：

假设我们计算出的相似度分别是：

$$1. \text{sim}(q, q_1) = 0.95$$

$$2. \text{sim}(q, q_2) = 0.90$$

$$3. \text{sim}(q, q_3) = 0.85$$

那么答案相关性得分 AR 为：

$$AR = \frac{1}{3} (0.95 + 0.90 + 0.85) = 0.90$$

这个得分反映了生成的答案与原始问题的对齐程度。如果 AR 得分接近1，这意味着生成的答案非常相关；如果得分低，可能意味着答案虽然正确，但可能不完全针对问题，或包含了一些与问题不直接相关的信息。在我们的例子中， AR 得分是0.90，这意味着生成的答案与原始问题非常相关。

3.6 上下文相关性

- 上下文 $c(q)$ 的相关性是指它在多大程度上仅包含回答问题 q 所需的信息。
- 评估上下文相关性时，LLM会从上下文 $c(q)$ 中提取一组句子 S_{ext} ，这些句子对回答问题 q 至关重要。
- 使用的提示是："Please extract relevant sentences from the provided context that can potentially help answer the following question. If no relevant sentences are found, or if you believe the question cannot be answered from the given context, return the phrase 'Insufficient Information'. While extracting candidate sentences you're not allowed to make any changes to sentences from given context."
- 上下文相关性得分 CR 通过公式 $CR = \frac{\text{number of extracted sentences}}{\text{total number of sentences in } c(q)}$ 计算，此指标旨在惩罚冗余信息的包含。

举例讲解：

场景设定：

想象我们正在使用一个语言模型来回答关于“长城”的问题。问题 q 是：“长城是在哪个朝代修建的？”系统检索到的上下文 $c(q)$ 包含了关于长城的一段历史描述，其中包含多个句子，有的与长城的建设时间相关，有的描述了长城的其他特征。

步骤 1：提取关键句子

我们需要从提供的上下文 $c(q)$ 中提取出对回答问题 q 至关重要的句子 S_{ext} 。我们可以给LLM以下提示：

请从提供的上下文中提取相关句子，这些句子可能有助于回答以下问题。如果没有找到相关句子，或者您认为问题不能用给定上下文回答，请返回短语“信息不足”。在提取候选句子时，不允许对给定上下文中的句子进行任何修改。

步骤 2：LLM执行句子提取

LLM根据提示从上下文中提取相关句子。例如，如果上下文中有10个句子，LLM可能确定其中3个句子直接回答了问题。

步骤 3：计算上下文相关性得分

上下文相关性得分 CR 是提取的相关句子数量与上下文中句子总数的比例。公式如下：

$$CR = \frac{\text{提取的相关句子数量}}{\text{上下文中句子总数}}$$

例子中的计算：

假设上下文 $c(q)$ 包含以下句子：

1. 长城是中国的象征。
2. 它的建设始于春秋时期。
3. 秦始皇统一六国后开始修建长城。
4. 长城在明朝得到了大规模的修缮和扩建。
5. 长城是世界上最长的墙。
6. 它是一项巨大的防御工程。
7. ...

如果问题是关于长城修建的朝代，那么句子2和句子4是直接相关的。如果LLM正确提取了这两个句子作为回答问题所需的信息，而总共有10个句子，那么：

$$CR = \frac{2}{10} = 0.2$$

这个得分表明，从上下文中提取的相关信息在总信息中所占的比例。得分越高，表示提取的上下文越专注于问题所需的信息。在我们的例子中，上下文相关性得分是0.2，意味着从整个上下文中提取的信息对问题的相关性只有20%。这可能表明上下文中包含了很多其他不相关的信息，或者LLM在提取相关信息时过于保守。

4 WikiEval 数据集

4.1 数据集构建步骤

1. 选取50个维基百科页面，这些页面涵盖了2022年开始的事件。
2. 优先选择最近有编辑的页面。
3. 对于这50个页面的每一个，使用ChatGPT根据页面的导言部分提出一个问题。

4.2 提问规则

- 问题应该能够完全由给定的上下文回答。
- 问题应该基于包含非琐碎信息的部分提出。

- 答案不应包含任何链接。
- 问题难度应该是中等。
- 问题必须合理，并且能够被人类理解和回答。
- 在问题中不使用“提供的上下文”等短语。

4.3 回答规则

- 使用给定上下文的信息来回答问题。

4.4 质量维度注释

- 所有问题都根据忠实度、答案相关性和上下文相关性这三个质量维度由两名注释者进行注释。
- 两名注释者都能流利使用英语，并且被清楚地指导了这三个质量维度的含义。
- 对于忠实度和上下文相关性，两名注释者在大约95%的情况下达成一致。
- 对于答案相关性，他们在大约90%的情况下达成一致。
- 分歧在注释者之间的讨论后解决。

5 实验

5.1 实验设计

1. 表1分析了第3节提出的评估指标与WikiEval数据集人类评估之间的一致性。
2. WikiEval实例要求模型比较两个答案或两个上下文片段。
3. 计算模型偏好的答案/上下文（最高估计的忠实度、答案相关性或上下文相关性）与人类注释者偏好的频率。
4. 结果以准确度报告（即模型与注释者一致的实例比例）。

5.2 比较基线方法

1. 使用ChatGPT为三个质量维度分配0到10的分数，称为GPT Score。
2. 提供定义质量指标的提示，然后要求评分。
 - 例如，评估忠实度时使用的提示：

忠实度测量答案与给定上下文的信息一致性。任何在答案中提出但无法从上下文中推断出的声明都应该受到惩罚。给出一个答案和上下文，为忠实度分配一个0-10的分数。

上下文：[Context]

答案：[Answer]

3. 如果LLM给出相同分数的答案候选，则随机打破平局。
4. 第二个基线方法，称为GPT Ranking，要求ChatGPT选择首选的答案/上下文。

5.3 结果概述

- 表1的结果显示，所提出的指标与人类判断的一致性高于两个基线方法。

	Faith.	Ans. Rel.	Cont. Rel.
RAGAs	0.95	0.78	0.70
GPT Score	0.72	0.52	0.63
GPT Ranking	0.54	0.40	0.52

Table 1: Agreement with human annotators in pairwise comparisons of faithfulness, answer relevance and context relevance, using the WikEval dataset (accuracy).

- 对于忠实度，RAGAs预测通常非常准确。
- 对于答案相关性，一致性较低，这主要是因为两个答案候选之间的差异通常非常微妙。
- 上下文相关性是最难评估的质量维度。观察到ChatGPT在选择关键句子时经常面临挑战，尤其是在上下文较长的情况下。

Question	Context	Answer
Who directed the film Oppenheimer and who stars as J. Robert Oppenheimer in the film?	Oppenheimer is a 2023 biographical thriller film written and directed by Christopher Nolan. Based on the 2005 biography American Prometheus by Kai Bird and Martin J. Sherwin, the film chronicles the life of J. Robert Oppenheimer, a theoretical physicist who was pivotal in developing the first nuclear weapons as part of the Manhattan Project, and thereby ushering in the Atomic Age. Cillian Murphy stars as Oppenheimer, with Emily Blunt as Oppenheimer's wife Katherine "Kitty" Oppenheimer.	<i>High Faithfulness:</i> Christopher Nolan directed the film Oppenheimer. Cillian Murphy stars as J. Robert Oppenheimer in the film. <i>Low Faithfulness:</i> James Cameron directed the film Oppenheimer. Tom Cruise stars as J. Robert Oppenheimer in the film.

Table 2: Example from WikiEval, showing answers with high and low faithfulness.

Question	Answer
When is the scheduled launch date and time for the PSLV-C56 mission, and where will it be launched from?	<i>High answer relevance:</i> The PSLV-C56 mission is scheduled to be launched on Sunday, 30 July 2023 at 06:30 IST / 01:00 UTC. It will be launched from the Satish Dhawan Space Centre, Sriharikota, Andhra Pradesh, India. <i>Low answer relevance:</i> The scheduled launch date and time for the PSLV-C56 mission have not been provided. The PSLV-C56 mission is an important space mission for India. It aims to launch a satellite into orbit to study weather patterns.

Table 3: Example from WikiEval, showing answers with high and low answer relevance.

Question	Context
When was the Chinnabai Clock Tower completed, and who was it named after?	<i>High context relevance:</i> The Chinnabai Clock Tower, also known as the Raopura Tower, is a clock tower situated in the Raopura area of Vadodara, Gujarat, India. It was completed in 1896 and named in memory of Chinnabai I (1864–1885), a queen and the first wife of Sayajirao Gaekwad III of Baroda State. <i>Low context relevance:</i> The Chinnabai Clock Tower, also known as the Raopura Tower, is a clock tower situated in the Raopura area of Vadodara, Gujarat, India. It was completed in 1896 and named in memory of Chinnabai I (1864–1885), a queen and the first wife of Sayajirao Gaekwad III of Baroda State. It was built in Indo-Saracenic architecture style. History. Chinnabai Clock Tower was built in 1896. The tower was named after Chinnabai I (1864–1885), a queen and the first wife of Sayajirao Gaekwad III of Baroda State. It was inaugurated by Mir Kamaluddin Hussainkhan, the last Nawab of Baroda. During the rule of Gaekwad, it was a stoppage for horse drawn trams. The clock tower was erected at the cost of 25,000 (equivalent to 9.2 million or USD 120,000 in 2023).

Table 4: Example from WikiEval, showing answers with high and low context relevance.

6 结论

- 强调了对RAG系统进行自动化、无需参考的评估的需求。
- 论述了需要一个能够评估忠实度、答案相关性和上下文相关性的评估框架。
- 为了支持这样的框架开发，介绍了包含这三个不同方面人类判断的WikiEval数据集。
- 描述了RAGAs，即实施这三个考虑的质量方面的框架。该框架易于使用，即使在没有任何基准真理的情况下，也能为RAG系统的开发者提供有价值的见解。
- WikiEval上的评估表明，RAGAs的预测与人类预测密切相关，尤其是在忠实度和答案相关性方面。