LLM+RAG 论文笔记

论文-1

来源：论文名称：Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
团队：Meta

问题：(1) 预训练语言模型在访问和操作知识方面的限制
(2) 模型决策来源和知识更新为未解决问题

方案：① 将预训练、参数化记忆的生成模型与非参数化记忆结合起来。
② RAG模型，参数化记忆为预训练seq2seq模型，非参数化记忆为Wikipedia的密集向量索引，通过预训练的DPR检索器访问。
③ 结合概率模型端到端训练，DPR提供条件文档，seq2seq模型（如BART）根据这些文档的条件生成输出。

图示：

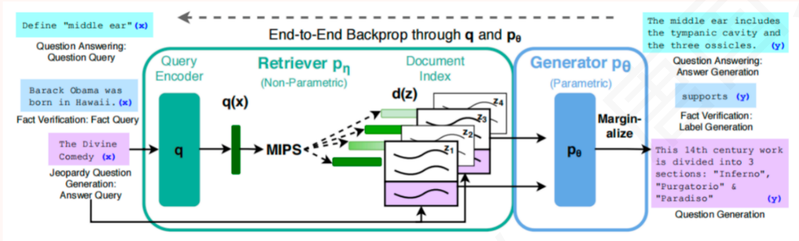

图1: 我们的方法概览。我们结合了一个预训练的检索器（查询编码器 + 文档索引）与一个预训练的序列到序列模型（生成器）并进行端到端的微调。对于查询 x，我们使用最大内积搜索（MIPS）来找到排名最高的 K 个文档 z_i。对于最终预测 y，我们将 z 视为一个潜变量，并在不同文档中对序列到序列预测进行边缘化。

论文-2

来源：论文名称：Bridging the Preference Gap between Retrievers and LLMs
论文团队：Google

问题：(1) 检索器与LLMs之间的关系未被充分探索，而是将检索器和LLM看作独立组件，导致LLMs和现有检索器之间的不同偏好。
(2) 对排名和选择的经验研究表明，LLMs对检索结果的排名不那么敏感，而选择可能更为关键。

方案：① 提出了一个名为BGM的新模型，该模型在检索器和LLM之间起到桥梁的作用，将检索信息转换成LLMs可以有效工作的格式。
② BGM专注于LLMs和检索器之间的偏好差异，不微调LLMs或检索器，而是在它们之间训练一个桥接模型，桥接模型是一个seq2seq模型，它将所有检索到的段落作为输入，输出一组适应的段落。
③ 给定从桥接模型中获得的适应段落作为上下文，将它们与输入x连接，并将得到的长序列送入LLM，以获得下游任务的输出。

图示：

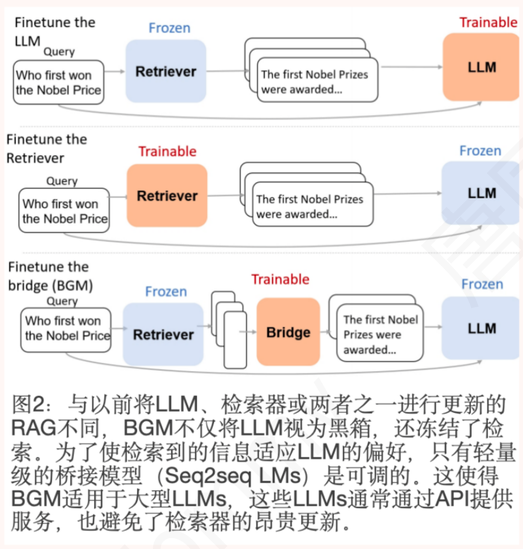

图2：与以前将LLM、检索器或两者之一进行更新的RAG不同，BGM不仅将LLM视为黑箱，还冻结了检索。为了使检索到的信息适应LLM的偏好，只有轻量级的桥接模型（Seq2seq LMs）是可调的。这使得BGM适用于大型LLMs，这些LLMs通常通过API提供服务，也避免了检索器的昂贵更新。

论文-3

来源：论文名称：ACTIVERAG: Revealing the Treasures of Knowledge via Active Learning
论文团队：东北大学

问题：(1) LLMs常常受到幻觉问题和过时参数记忆的影响，导致输出不可靠。
(2) RAG模型通过检索外部语料库，建立了基于暴力检索的RAG体系结构，但这种方法的有效性受到检索知识噪音的影响。

方案：① ACTIVE RAG引入了积极学习机制，改变了LLMs的知识获取方式；
② 采用了知识构建机制，通过将外部知识与先前获得或记忆的知识相关联，促进深入理解；
③ 设计了认知连接机制，将思维和知识构建的成果融合，校准LLMs的内在认知。

图示：

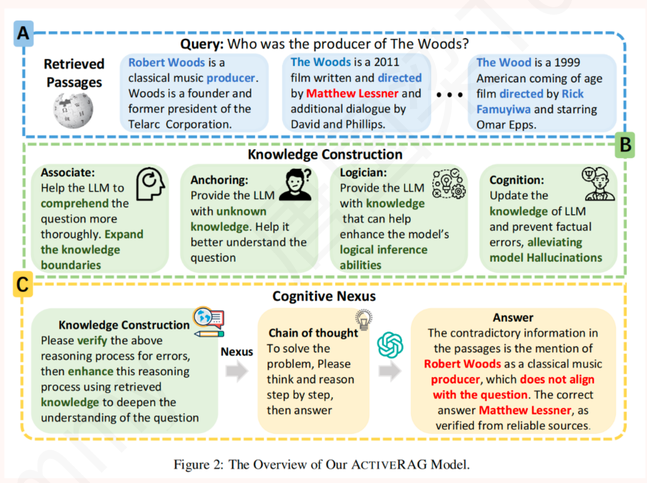

Figure 2: The Overview of Our ACTIVERAG Model.

A. 检索的文章（Retrieved Passages）

图片的左上角部分展示了一个查询："The Woods"的制作人是谁。为回答这个问题，列出了几个检索到的相关文章。这些文章包含有关Robert Woods的信息，他是一位古典音乐制作人，也是Telarc Corporation的创始人和前总裁。还有关于2011年由Matthew Lessner编写并导演的电影"The Woods"的信息，以及1999年由Rick Famuyiwa导演，Omar Epps主演的电影"The Wood"的信息。

B. 知识构建（Knowledge Construction）

在检索的文章下方，介绍了四种知识构建方法：
– Associate：帮助LLM更全面地理解问题，扩展知识边界。
– Anchoring：为LLM提供未知知识，帮助其更好地理解问题。
– Logician：为LLM提供可以增强模型逻辑推理能力的知识。
– Cognition：更新LLM的知识，防止事实错误，减轻模型的错觉问题。

C. 认知连接（Cognitive Nexus）

图片中心下方展示了认知连接部分，这是ACTIVE RAG模型的一个关键环节，它通过"思维链"（chain of thought）的方式，指导解决问题的过程。指示LLM进行逐步思考和推理，然后给出答案。认知连接旨在验证上述推理过程中的错误，然后利用检索到的知识加深对问题的理解。
文章中的矛盾信息是提到Robert Woods作为一位古典音乐制作人，这与问题不符。正确的答案是Matthew Lessner，这一答案经过可靠来源验证。

Active RAG设计了三步流水线，包括检索、知识构建和认知连接。
Active RAG着重于通过桥接检索到的文章和LLMs先前学到的知识之间的差距来进行主动知识学习，无需微调。

论文-4

来源：论文名称：Corrective Retrieval Augmented Generation
论文团队：中科大

问题：(1) 大语言模型（LLMs）在生成文本时存在准确性问题，会出现"幻觉"。
(2) 检索增强生成（RAG）是LLMs的补充方法，但过度依赖检索文档的相关性。

方案：CRAG，一种可插拔的自我修正方法，提高文档使用效率。引入轻量级检索评估器，对检索到的文档整体质量进行评估。

图示：

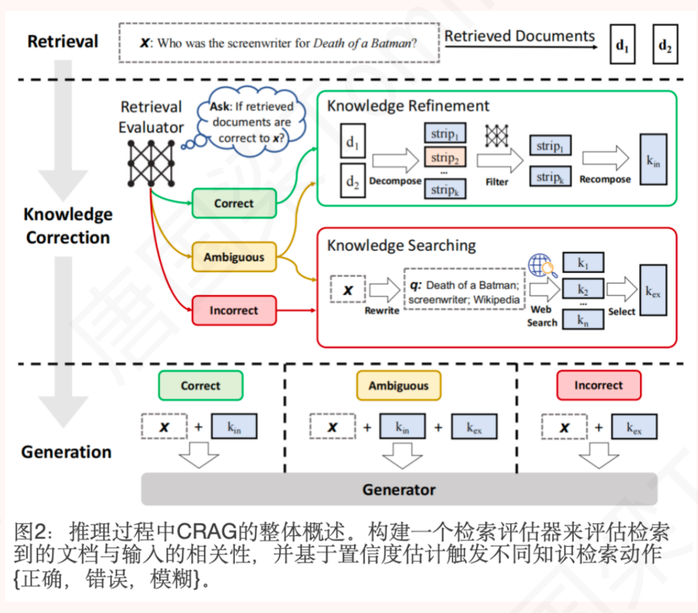

图2：推理过程中CRAG的整体概述。构建一个检索评估器来评估检索到的文档与输入的相关性，并基于置信度估计触发不同知识检索动作{正确，错误，模糊}。

CRAG在推断时设计了纠正策略来提高生成器的稳健性。
– 针对输入查询和检索到的文档，构建了轻量级的检索评估器以估计相关性分数。
– 计算出的相关性分数被量化为三种信心度{正确，错误，模糊}，并触发相应的操作。
– 如果触发"正确"操作，将对检索到的文档进行精细化处理；如果是"错误"，则丢弃文档，并转而使用网络搜索作为补充知识源（4.5节）。
– 系统在无法确信判断正确或错误时，将触发一个综合两者的"模糊"操作。
– 优化检索结果后，可以随后采用任意生成模型来生成最终结果。

论文-5

来源：论文名称：DREditor: An Time-efficient Approach for Building a Domain-specific Dense Retrieval Model
团队名称：四川大学

问题：① DR模型的增长和复杂性导致小型和中型企业面临时间和计算资源的挑战。
② 通用的DR模型不能适应多个企业，因为它们在不同领域的泛化能力不足。
③ 现有的微调方法（adapter fine-tuning）耗时且需要大量计算资源。

方案：① 提出了一种称为DREditor的时间高效方法来编辑DR模型的匹配规则，使其适应特定领域。
② 使用有效的线性映射技术直接校准输出嵌入，无需长时间的参数优化。
③ 通过解决特别构造的最小二乘问题以闭合形式（closed form）计算编辑算子，提高计算效率。

图示：

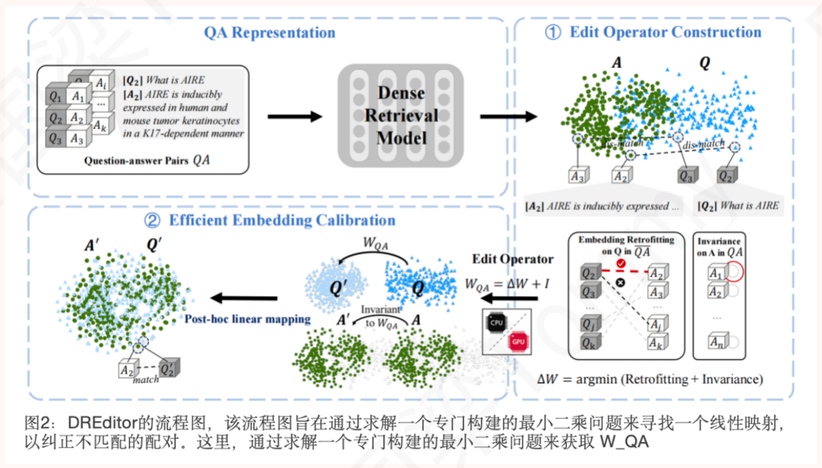

图2：DREditor的流程图，该流程图旨在通过求解一个专门构建的最小二乘问题来寻找一个线性映射，以纠正不匹配的配对。这里，通过求解一个专门构建的最小二乘问题来获取 W_QA

欢迎关注B站/公众号/YouTube：唐国梁Tommy